# Temporal Difference Method

Prof. Tae-Hyoung Park
Dept. of Intelligent Systems & Robotics, CBNU

### Temporal Difference 방법

- (MC 법 vs. TD 법
  - MC (Monte Carlo) 법
    - 에피소드가 끝에 도달한 후 <u>가치함수(Q)</u> 계산 → 정책평가 (policy evaluation) → 정책갱신 (policy update)
    - 일회성 과제 (O), 지속성 과제 (X)
  - TD (Temporal Difference (시간차)) 법
    - 에피소드가 끝날 때 까지 기다리지 않고, 일정 시간 마다 정책평가 및 정책 갱신
    - 일회성 과제 (O), 지속성 과제 (O)
    - TD 법 = MC 법 + DP 법

Return

$$G_t = R_t + \gamma R_{t+1} + \gamma^2 R_{t+2} + \cdots$$
$$= R_t + \gamma G_{t+1}$$

Value Function

$$v_{\pi}(s) = \mathbb{E}_{\pi}[G_t \mid S_t = s]$$
$$= \mathbb{E}_{\pi}[R_t + \gamma G_{t+1} \mid S_t = s]$$

- DP 법
  - 다음상태의 가치로 부터 현재상태의 가치 추정 (bootstrap)
  - 환경에 대한 모델링을 통하여, 모든 경우의 상태 전이를 고려함

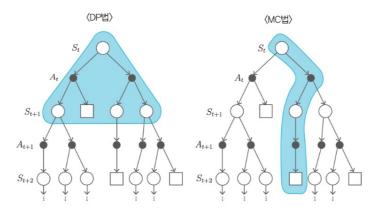
$$V'_{\pi}(s) = \sum_{a,s'} \pi(a \mid s) p(s' \mid s,a) \{ r(s,a,s') + \gamma V_{\pi}(s') \}$$

(Bellman equation)

- MC 법
  - 특정한 sample data (현재상태→최종상태) 의 return 평균

$$V'_{\pi}(S_t) = V_{\pi}(S_t) + \alpha \{G_t - V_{\pi}(S_t)\}$$

(Exponential moving average)



#### • TD 법

- DP 법 처럼 bootstrap 을 통해 가치함수를 순차적으로 갱신 (다음상태→현재상태)
- MC법 처럼 환경에 대한 정보 없이 sampling 된 데이터 만으로 가치함수 갱신

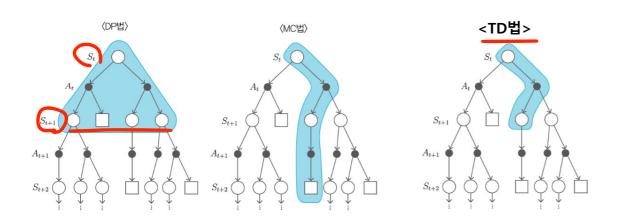
$$V'_{\pi}(S_{t}) = V_{\pi}(S_{t}) + \alpha \{R_{t} + \gamma V_{\pi}(S_{t+1}) - V_{\pi}(S_{t})\}$$

〈MC법〉 
$$V'_{\pi}(S_t) = V_{\pi}(S_t) + \alpha \left\{ G_t - V_{\pi}(S_t) \right\}$$

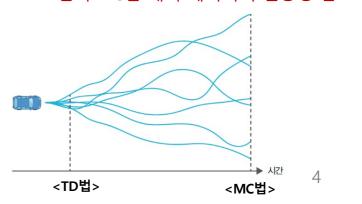
〈TD법〉 
$$V_\pi'(S_t) = V_\pi(S_t) + \alpha \left\{ R_t + \gamma V_\pi(S_{t+1}) - V_\pi(S_t) \right\}$$
 TD Target

 $G_t$ : 목표에 도달 시 얻을 수 있는 수익, 현재 $\rightarrow$ 목표까지의 샘플필요

 $R_t + \gamma V_{\pi}(S_{t+1})$ : 목표에 도달 시 얻을 수 있는 수익 (추정치) 현재 $\rightarrow$ 다음까지의 샘플 필요



#### ✓ TD법이 MC법 대비 데이터의 변동성 감소



- TD 법 구현
  - TdAgent Class

```
class TdAgent:
   def init (self):
        self.gamma = 0.9
        self.alpha = 0.01
        self.action size = 4
        random_actions = {0: 0.25, 1: 0.25, 2: 0.25, 3: 0.25}
        self.pi = defaultdict(lambda: random_actions)
        self.V = defaultdict(lambda: 0)
   def get_action(self, state):
        action probs = self.pi[state]
        actions = list(action_probs.keys())
        probs = list(action probs.values())
                                                                                    <MC 법>
                                                        매 step 마다 계산
        return np.random.choice(actions, p=probs)
                                                                                                       목표 도달 시 계산
   def eval(self, state, reward, next_state, done):
                                                                                   def eval(self):
                                                                                      G = 0
        next V = 0 if done else self.V[next_state] # 목표 지점의 가치 함수는 0
                                                                                      for data in reversed(self.memory): # 역방향으로(reserved) 따라가기
        target = reward + self.gamma * next V
                                                                                          state, action, reward = data
                                                                                          G = self.gamma * G + reward
                                                                                          self.cnts[state] += 1
        self.V[state] += (target - self.V[state]) * self.alpha
                                                                                          self.V[state] += (G - self.V[state]) / self.cnts[state]
              V'_{\pi}(S_t) = V_{\pi}(S_t) + \alpha \{R_t + \gamma V_{\pi}(S_{t+1}) - V_{\pi}(S_t)\}
```

#### • TD 법 구현

```
env = GridWorld()
agent = TdAgent()

episodes = 1000

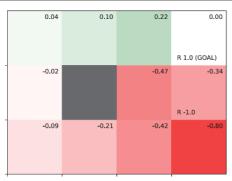
for episode in range(episodes):
    state = env.reset()

while True:
    action = agent.get_action(state)
    next_state, reward, done = env.step(action)

agent.eval(state, reward, next_state, done) # 대변 호출

if done:
    break
    state = next_state

env.render_v(agent.V)
```



#### <MC 법>

```
env = GridWorld()
agent = RandomAgent()
episodes = 1000
for episode in range(episodes): # 에피소드 1000번 수행
   state = env.reset()
   agent.reset()
   while True:
       action = agent.get_action(state)
       next_state, reward, done = env.step(action) # 행동 수행
       agent.add(state, action, reward) # (상태, 행동, 보상) 저장
       if done: # 목표에 도달 시
           agent.eval() # 몬테카를로법으로 가치 함수 갱신
           break
                        # 다음 에피소드 시작
       state = next state
 # 가치 함수 시각화
                                       0.08
                                               0.21
 env.render_v(agent.V)
                                                  R 1.0 (GOAL)
                               -0.03
                                                  R -1.0
                               -0.09
                                                          6
```

#### 실습 #1 td\_eval.py

```
from collections import defaultdict
import numby as no
from common.gridworld import GridWorld
class TdAgent:
   def __init__(self):
       self.gamma = 0.9
       self.alpha = 0.01
       self.action size = 4
       random_actions = \{0: 0.25, 1: 0.25, 2: 0.25, 3: 0.25\}
       self.pi = defaultdict(lambda: random_actions)
       self.V = defaultdict(lambda: 0)
   def get_action(self. state):
       action probs = self.pi[state]
       actions = list(action probs.kevs())
       probs = list(action probs.values())
       return np.random.choice(actions, p=probs)
   def eval(self. state, reward, next state, done);
       next_V = 0 if done else self.V[next_state] # 목표 지점의 가치 함수는 0
       target = reward + self.gamma * next_V
       self.V[state] += (target - self.V[state]) * self.alpha
```

```
env = GridWorld()
agent = TdAgent()

episodes = 1000
for episode in range(episodes):
    state = env.reset()

while True:
    action = agent.get_action(state)
    next_state, reward, done = env.step(action)

agent.eval(state, reward, next_state, done) # 매번 호출
    if done:
    break
    state = next_state

# 가치 함수 시각화
env.render_v(agent.V)
```

- Value Function Update (TD 법)
  - State-value function

$$V'_{\pi}(S_{t}) = V_{\pi}(S_{t}) + \alpha \{R_{t} + \gamma V_{\pi}(S_{t+1}) - V_{\pi}(S_{t})\}$$

Action-value function

$$Q'_{\pi}(S_{t}, A_{t}) = Q_{\pi}(S_{t}, A_{t}) + \alpha \{R_{t} + \gamma Q_{\pi}(S_{t+1}, A_{t+1}) - Q_{\pi}(S_{t}, A_{t})\}$$

Policy Update

$$\pi'(a \mid S_t) = \begin{cases} rgmax \ Q_{\pi}(S_t, a) & (1 - \varepsilon$$
의확률) 무작위행동  $(\varepsilon$ 의확률)

- SARSA
  - TD 법으로 Q 함수를 구하고, ε-greedy 로 정책을 개선하는 방법

$$S_t \quad A_t \quad R_t \quad S_{t+1} \quad A_{t+1}$$

$$(S_t, A_t, R_t, S_{t+1}, A_{t+1})$$
  
S. A. R. S. A

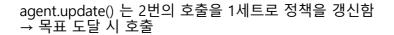
**SARSA** 

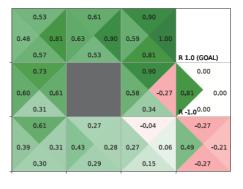
#### Implementation

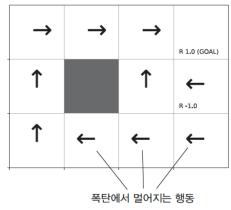
```
class SarsaAgent:
    .....
def __init_ (self):
   self.gamma = 0.9
   self.alpha = 0.8
   self.epsilon = 0.1
   self.action size = 4
   random_actions = {0: 0.25, 1: 0.25, 2: 0.25, 3: 0.25}
   self.pi = defaultdict(lambda: random_actions)
   self.Q = defaultdict(lambda: 0)
   self.memory = deque(maxlen=2) # ① deque 사용
                                                                     FIFO, 최근 2개 데이터 보관
deт update(self, state, action, reward, done):
   self.memory.append((state, action, reward, done))
   if len(self.memory) < 2:</pre>
      return
   state, action, reward, done = self.memory[0]
   next_state, next_action, _, = self,memory[1]
   # 6 다음 0 함수
   next_q = 0 if done else self.Q[next_state, next_action]
   # 4 TD법으로 self.Q 갱신
   target = reward + self.gamma * next q
  # 6 정책 개선
   self.pi[state] = greedy probs(self.Q, state, self.epsilon)
```

#### Implementation

```
env = GridWorld()
agent = SarsaAgent()
episodes = 10000
for episode in range(episodes):
    state = env.reset()
   agent.reset()
    while True:
       action = agent.get action(state)
       next_state, reward, done = env.step(action)
       agent.update(state, action, reward, done) # ① 매번 호출
       if done:
           # 🔴 목표에 도달했을 때도 호출
           agent.update(next_state, None, None, None)
            break
        state = next_state
env.render_q(agent.Q) # Q 함수 시각화
```







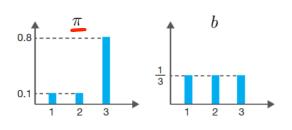
#### 실습 #2 sarsa.py

```
from collections import defaultdict, deque
import numpy as no
from common.gridworld import GridWorld
from common.utils import greedy probs
class SarsaAgent:
   def __init__(self):
       self.gamma = 0.9
       self.alpha = 0.8
       self.epsilon = 0.1
       self.action_size = 4
       random actions = \{0: 0.25, 1: 0.25, 2: 0.25, 3: 0.25\}
       self.pi = defaultdict(lambda: random actions)
       self.Q = defaultdict(lambda: 0)
       self.memory = deque(maxlen=2) # deque 사용
    def get action(self. state):
       action_probs = self.pi[state] # pi에서 선택
       actions = list(action_probs.keys())
       probs = list(action probs.values())
       return np.random.choice(actions, p=probs)
   def reset(self):
       self.memorv.clear()
   def update(self. state, action, reward, done):
       self.memory.append((state, action, reward, done))
       if len(self.memory) < 2:
           return
```

```
state, action, reward, done = self.memorv[0]
       next_state, next_action, _, _ = self.memory[1]
       next q = 0 if done else self.Q[next state, next action] # 다음 Q 함수
       # TD법으로 self.Q 갱신
       target = reward + self.gamma * next q
       self.Q[state, action] += (target - self.Q[state, action]) * self.alpha
       # 정책 개선
       self.pi[state] = greedy probs(self.Q. state, self.epsilon)
env = GridWorld()
agent = SarsaAgent()
episodes = 10000
for episode in range(episodes):
   state = env.reset()
   agent.reset()
    while True:
       action = agent.get action(state)
       next state, reward, done = env.step(action)
       agent.update(state. action, reward, done) # 매번 호출
       if done:
           # 목표에 도달했을 때도 호출
           agent.update(next_state, None, None, None)
           break
       state = next state
# 시각화
env.render_q(agent.Q)
```

### Importance Sampling

- Definition
  - 확률분포  $\pi$  의 기대값을 다른 확률분포 (b) 에서 샘플링한 데이터를 사용하여 계산하는 기법
- 워리



$$\mathbb{E}_{\pi}[x] = \sum x\pi(x)$$

$$= \sum x \frac{b(x)}{b(x)} \pi(x)$$

$$= \sum x \frac{\pi(x)}{b(x)} b(x)$$

$$= \mathbb{E}_{b} \left[ x \frac{\pi(x)}{b(x)} \right]$$

• 방법

E= ()()=

확률분포 b 에서의 샘플링:

Sampling: 
$$x^{(i)} \sim b$$
  $(i = 1, \dots, n)$ 

$$\rho(x) = \frac{\pi(x)}{b(x)}$$

$$\mathbb{E}_{\pi}[x] \approx \frac{\rho(x^{(1)})x^{(1)} + \dots + \rho(x^{(n)})x^{(n)}}{n}$$

## Importance Sampling

```
import numpy as np
x = np.array([1, 2, 3]) # 확률 변수
pi = np.array([0.1, 0.1, 0.8]) # 확률 분포
                                              \pi(x)
# 기댓값의 참값 계산
                                              E_{\pi}(x)
e = np.sum(x * pi)
print('참값(E pi[x]):', e)
# 몬테카를로법으로 계산
n = 100 # 샘플 개수
samples = []
for in range(n):
   s = np.random.choice(x, p=pi) # pi를 이용한 샘플링 \pi \sim x^{(1)} + \cdots + x^{(n)}
   samples.append(s)
                                                 E_{\pi}(x) = \frac{x^{(1)} + \dots + x^{(n)}}{x}
   mean = np.mean(samples) # 샘플들의 평균
   var = np.var(samples) # 샘플들의 분산
   print('몬테카를로법: {:.2f} (분산: {:.2f})'.format(mean, var))
#중요도 샘플링으로 계산
                                                                               두 확률 분포가 유사하면 샘플링의 분산이 작아짐
b = np.array([1/3, 1/3, 1/3]) # 확률 분포
n = 100 # 샘플 개수
samples = []
                                                                               (ex) b = np.array(0.2,0.2,0.6)
                                                                                   => mean = 2.72, var = 2.48)
for _ in range(n):
   idx = np.arange(len(b))
                             # b의 인덱스([0, 1, 2])
   i = np.random.choice(idx, p=b) # b를 사용하여 샘플링
                                                    h \sim \chi^{(1)} + \cdots + \chi^{(n)}
   s = x[i]
   rho = pi[i] / b[i]
                              # 가중치
   samples.append(rho * s)
                                # 샘플 데이터에 가중치를 곱해 저장
                                                   E_{\pi}(x) = \frac{\rho(x^{(1)})x^{(1)} + \dots + \rho(x^{(n)})x^{(n)}}{n}
mean = np.mean(samples)
var = np.var(samples)
print('중요도 샘플링: {:.2f} (분산: {:.2f})'.format(mean, var))
```

참값(E pi[x]): 2.7

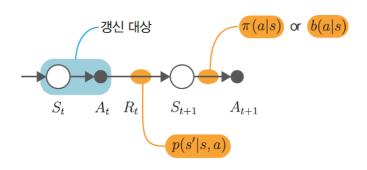
몬테카를로법: 2.78 (분산: 0.27) 중요도 샘플링: 2.95 (분산: 10.63)

### On-Policy vs. Off-Policy

- On-Policy
  - 스스로 쌓은 경험을 토대로 자신의 정책을 개선
  - '대상 정책 (target policy)' 와 '행동 정책 (behavior policy)' 가 동일함
- Off-Policy
  - 자신과 다른 환경에서 쌓은 경험을 토대로 자신의 정책을 개선
     (ex) 다른 테니스 선수가 스윙하는 모습을 보고 자신의 스윙 자세를 고침
  - '대상 정책' 과 '행동 정책' 이 구분됨
- '행동 정책'(b) 에서 얻은 샘플 데이터로부터 '대상 정책' $(\pi)$  의 기댓값을 계산하는 방법
  - 중요도 샘플링 (importance sampling) 필요
  - 정책의 최적성이 향상됨

## Off-Policy SARSA

- 행동 정책과 대상 정책
  - 대상 정책  $\pi$ 
    - Policy upgrade: greedy (exploitation)
  - 행동 정책 b
    - Policy upgrade: e-greedy (exploration)



$$\rho = \frac{\pi(A_{t+1}|S_{t+1})}{b(A_{t+1}|S_{t+1})}$$

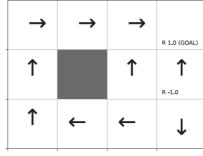
### Off-Policy SARSA

#### Implementation

```
class SarsaOffPolicyAgent:
   def init (self):
        self.gamma = 0.9
        self.alpha = 0.8
        self.epsilon = 0 1
        self.action size = 4
        random_actions = {0: 0.25, 1: 0.25, 2: 0.25, 3: 0.25}
        self.pi = defaultdict(lambda: random actions)
        self.b = defaultdict(lambda: random_actions)
        self.Q = defaultdict(lambda: 0)
        self.memory = deque(maxlen=2)
    def get action(self, state):
        action probs = self.b[state] # ① 행동 정책에서 가져옴
        actions = list(action probs.keys())
        probs = list(action_probs.values())
        return np.random.choice(actions, p=probs)
    def reset(self):
        self.memory.clear()
```

```
def update(self, state, action, reward, done):
    self.memory.append((state, action, reward, done))
    if len(self.memory) < 2:</pre>
        return
    state, action, reward, done = self.memory[0]
   next_state, next_action, _, _ = self.memory[1]
    if done:
       next a = 0
       rho = 1
    else:
       next_q = self.Q[next state, next action]
       # ② 가중치 rho 계산
       rho = self.pi[next_state][next_action] / self.b[next_state][next_action]
    # 6 rho로 TD 목표 보정
   target = rho * (reward + self.gamma * next q)
   self.Q[state, action] += (target - self.Q[state, action]) * self.alpha
    # 4 각각의 정책 개선
   self.pi[state] = greedy probs(self.Q, state, 0)
    self.b[state] = greedy probs(self.Q, state, self.epsilon)
```



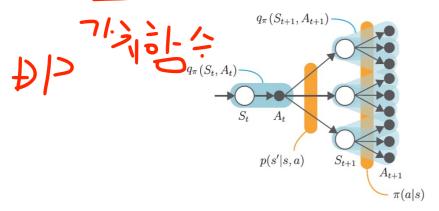


#### SARSA vs Q Learning

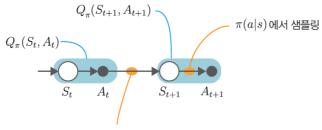
#### **SARSA**

(Bellman equation)

$$q_{\pi}(s,a) = \sum_{s'} p(s' | s,a) \left\{ r(s,a,s') + \gamma \sum_{a'} \pi(a' | s') q_{\pi}(s',a') \right\}$$



#### (Sampling version)



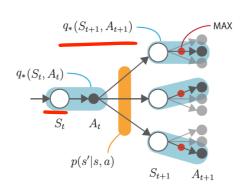
p(s'|s,a)에서 샘플링

$$Q'_{\pi}(S_{t}, A_{t}) = Q_{\pi}(S_{t}, A_{t}) + \alpha \{R_{t} + \gamma Q_{\pi}(S_{t+1}, A_{t+1}) - Q_{\pi}(S_{t}, A_{t})\}$$

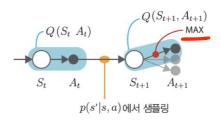
#### Q Learning

(Bellman optimality\_equation)

$$q.(s,a) = \sum_{s'} p(s' \mid s,a) \left\{ r(s,a,s') + \gamma \max_{a'} q.(s',a') \right\}$$

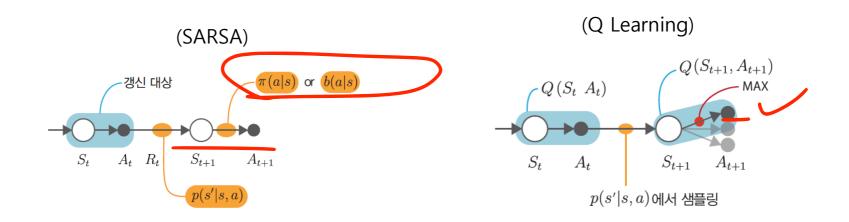


#### (Sampling version)



$$Q'(S_{t}, A_{t}) = Q(S_{t}, A_{t}) + \alpha \left\{ R_{t} + \gamma \max_{a} Q(S_{t+1}, a) - Q(S_{t}, A_{t}) \right\}$$
 17

- Off-Policy
  - SARSA
    - $A_{t+1}$  을 확률분포  $\pi$  또는 b 에서 샘플링
    - 중요도 샘플링 필요, Q 갱신 불안정
  - Q Learning
    - $A_{t+1}$  을 Q 함수가 가장 큰 (MAX) 행동으로 선택
    - 중요도 샘플링 불필요, Q 갱신 안정
    - 최적화 성능 향상



#### Implementation

```
class QLearningAgent:

def __init__(self):
    self.gamma = 0.9
    self.alpha = 0.8
    self.epsilon = 0.1
    self.action_size = 4

random_actions = {0: 0.25, 1: 0.25, 2: 0.25, 3: 0.25}

self.b = defaultdict(lambda: random_actions) # 행동 정책
    self.Q = defaultdict(lambda: 0)

def get_action(self, state):
    action_probs = self.b[state] # 행동 정책에서 가져옴
    actions = list(action_probs.keys())
    probs = list(action_probs.values())
    return np.random.choice(actions, p=probs)
```

```
def update(self, state, action, reward, next_state, done):
   if done: # 목표에 도달
        next_q_max = 0
else: # 그 외에는 다음 상태에서 Q 함수의 최댓값 계산
        next_qs = [self.Q[next_state, a] for a in range(self.action_size)]
        next_q_max = max(next_qs)

# Q 함수 갱신
target = reward + self.gamma * next_q_max
self.Q[state, action] += (target - self.Q[state, action]) * self.alpha
# 행동 정책 갱신
self.b[state] = greedy_probs(self.Q, state, self.epsilon)
```

```
Q'(S_{t}, A_{t}) = Q(S_{t}, A_{t}) + \alpha \left\{ R_{t} + \gamma \max_{a} Q(S_{t+1}, a) - Q(S_{t}, A_{t}) \right\}
```

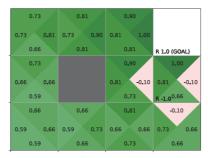
```
def update(self, state, action, reward, done):
   self.memory.append((state, action, reward, done))
   if len(self.memory) < 2:</pre>
       return
   state, action, reward, done = self.memory[0]
   next_state, next_action, _, = self.memory[1]
   if done:
       next_q = 0
       next_q = self.Q[next_state, next_action]
       # ② 가중치 rho 계산
       rho = self.pi[next_state][next_action] / self.b[next_state][next_action]
   # 🔞 rho로 TD 목표 보정
   target = rho * (reward + self.gamma * next_q)
   self.Q[state, action] += (target - self.Q[state, action]) * self.alpha
   # 4 각각의 정책 개선
   self.pi[state] = greedy_probs(self.Q, state, 0)
   self.b[state] = greedy_probs(self.Q, state, self.epsilon)
```

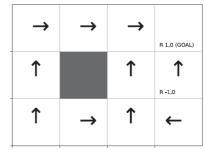
(off-policy SARSA)

#### 실습 #3 q\_learning.py

```
from collections import defaultdict
import numpy as no
from common.gridworld import GridWorld
from common.utils import greedy probs
class OlearningAgent:
   def init (self):
       self.gamma = 0.9
       self.alpha = 0.8
       self.epsilon = 0.1
       self.action_size = 4
       random\_actions = \{0: 0.25, 1: 0.25, 2: 0.25, 3: 0.25\}
       self.b = defaultdict(lambda: random_actions) # 행동 정책
       self.Q = defaultdict(lambda: 0)
   def get action(self. state):
       action_probs = self.b[state] # 행동 정책에서 가져옴
       actions = list(action probs.kevs())
       probs = list(action probs.values())
       return np.random.choice(actions. p=probs)
   def update(self. state, action, reward, next state, done);
       if done: #목표에 도달
           next = 0
       else: # 그 외에는 다음 상태에서 Q 함수의 최댓값 계산
           next_qs = [self.Q[next_state, a] for a in range(self.action_size)]
           next_q_max = max(next_qs)
```

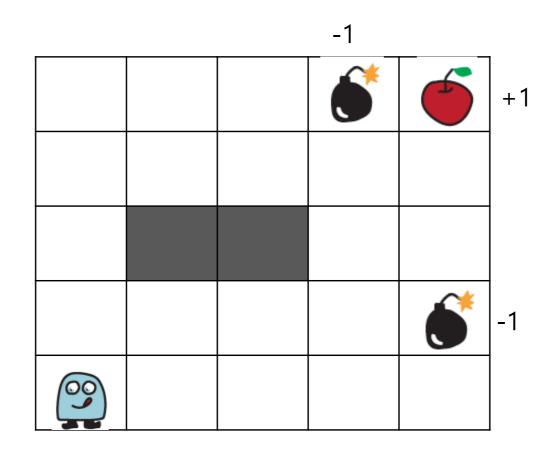
```
# 0 함수 갱신
        target = reward + self.gamma * next q max
        self.Q[state, action] += (target - self.Q[state, action]) * self.alpha
       # 행동 정책:
        self.b[state] = greedy probs(self.Q. state, self.epsilon)
env = GridWorld()
agent = QLearningAgent()
episodes = 10000
for episode in range(episodes):
    state = env.reset()
    while True:
       action = agent.get action(state)
       next state, reward, done = env.step(action)
        agent.update(state, action, reward, next state, done)
        if done:
           break
        state = next_state
# 시각화
env.render g(agent.Q)
```





### Quiz

(Q) Q Learning 을 적용하여 5x5 Grid World 에 대한 value function 및 policy 를 구하라.



- 요약
  - 상태 (state) 와 행동 (action) 에 대해 Q-value 를 업데이트 하면서, 보상을 최대화 하는 정책(policy) 을 학습
    - TD 법으로 가치함수 평가
      - MC 와 같이 샘플링 데이터 기반의 가치함수 평가
      - '지금' 과 '다음' 정보만 사용
    - Bellman optimality equation

$$Q'(S_{t}, A_{t}) = Q(S_{t}, A_{t}) + \alpha \left\{ R_{t} + \gamma \max_{a} Q(S_{t+1}, a) - Q(S_{t}, A_{t}) \right\}$$

- Off-Policy, but 중요도 샘플링 사용하지 않음
- ⇒ Q 함수를 효율적이고 안정적으로 갱신
- ⇒ 정책 결정의 최적화 성능 향상
- ⇒ 강화학습의 핵심기법으로 많은 연구의 기반 알고리즘으로 사용

#### History



- 1989, Q-Learning 등장
  - · Watkins & Dayan, "Q-Learning", Machine Learning
  - Q-table 학습
- 19♥0~2000년대 초반: 알고리즘 확장
  - SARSA (On-policy), Dyna-Q 등
  - 게임, 로보틱스 등에서 실험적으로 사용



- 2013, Deep Q-Network (DQN) 등장
  - Deep Mind (Mnih et al.), "Playing Atari with Deep Reinforcement Learning", 2013 (arXiv)
  - Q-table 대신 신경망으로 Q-value 를 근사
  - 인간 수준의 Atari 게임 플레이
- 최근, 다양한 DQN 변형 등장
  - Double DQN, Dueling DQN, Rainbow DQN ......