# Deep Q-Network (DQN)

Prof. Tae-Hyoung Park
Dept. of Intelligent Systems & Robotics, CBNU

# Q-learning vs Q-Network vs DQN

Cf. Policy based

항목	Q-Learning	Q-Network	DQN
방법론	Value based	←	<b>←</b>
Q 함수 표현 Q(s,a) 기-২	Table  0.53 0.61 0.59 0.62 0.48 0.81 0.63 0.63 0.89 0.89 0.89 0.80 0.81 0.90 0.00 0.00 0.61 0.27 0.04 0.41 0.58 0.27 0.00 0.31 0.61 0.27 0.04 0.27 0.39 0.30 0.29 0.15 0.30 0.29 0.15 0.30	Neural networks  s  day  0.7  0.3  0.5  1.7	↓
Q 함수 학습 (update)	Bellman optimality eq. $Q'(S_{p},A_{t}) = Q(S_{p},A_{t}) + a\{R_{t} + \gamma \max_{a} Q(S_{t+1},a) - Q(S_{p},A_{t})\}$	Error backpropagation (Gradient descent)  - 신경망 출력값= $Q(S_t,A_t)$ - 신경망 목표값= $\gamma \max_a Q(S_{t+1},a) + R_t$	←
		신경망 학습의 효율 및 안정성 문제	- Experience Replay 도입 - Target Network 도입
Action 선택 (policy)	ε-greedy	←	←
적용 환경	- Discrete state space - State space 크기가 작음	- Continuous state space 도 가능 - State space 크기가 큰 경우 도 가능	←

### OpenAl Gym

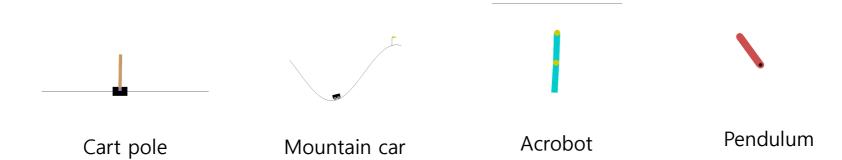
#### Basics

- Open source Python library for developing and comparing reinforcement algorithms
- Public beta version, 2016.04
- Documentation: https://www.gymlibrary.dev/\*

#### Environments

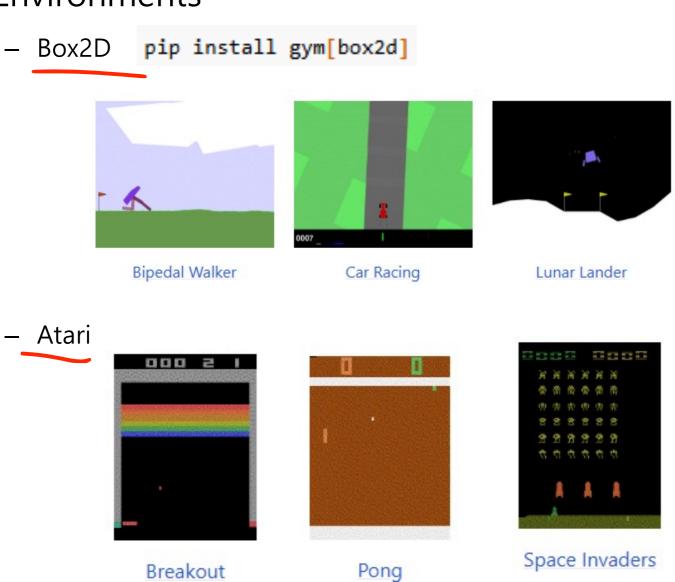
pip install gym[classic\_control]

Classic Control



# OpenAl Gym

#### Environments



# OpenAl Gym

#### Environments

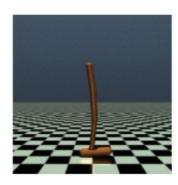
MuJoCo pip install gym[mujoco]





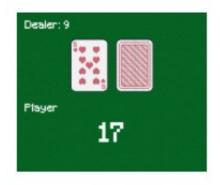


Half Cheetah

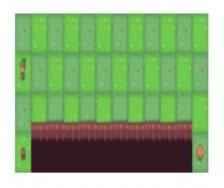


Hopper

#### Toy Text



Taxi



Blackjack

Cliff Walking

### Cart Pole

#### **Environment**

```
import gym
env = gym.make('CartPole-v0', render_mode='human')
```

- State (observation)
  - Cart position: -4.8 ~ 4.8

  - Cart velocity: -∞ ~ ∞
    Pole angle: -24(deg) ~ 24(deg)
    Pole angular velocity: -∞ ~ ∞
- Action
  - 0: Push cart to the left
  - 1: Push cart to the right
- Rewards
  - +1 for every step (goal is to keep the pole upright)
- Starting state
  - Uniformly random value in (-0.05, 0.05)
- Episode ends if any one of the following occurs
  - Pole angle is greater than  $\pm 12 \deg (\pm 0.209 \text{ rad})$
  - Cart position is greater then  $\pm 2.4$  (center of cart reaches the edge of display)
  - Episode length is greater then 500 (200 for v0)



### Cart Pole

#### Env.reset()

```
state = env.reset()[0] # 상태 초기화
print('상태:', state)
action_space = env.action_space
print('행동의 차원 수:', action_space)
```

```
상태: [ 0.03454657 -0.01361909 -0.02143636 0.02152179]
행동의 차원 수: Discrete(2)
```

### Env.step(action)

```
action = 0 # 혹은 1
next_state, reward, terminated, truncated, info = env.step(action)
print(next_state)
```

[ 0.03454657 -0.01361909 -0.02143636 0.02152179]

 • next\_state: 다음 상태

 • reward: 보상

 • terminated: 목표 상태 도달 여부
 각도초과, 위치 벗어남

 • truncated: MDP 범위 밖의 종료 조건 충족 여부(시간 초과 등)
 action 500회 (v0: 200회 초과)

### Cart Pole

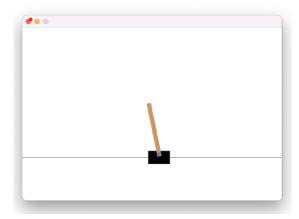
- Random Agent
  - 무작위로 행동 (action) 하는 agent

```
import numpy as np
import gym

env = gym.make('CartPole-v0', render_mode='human')
state = env.reset()[0]
done = False

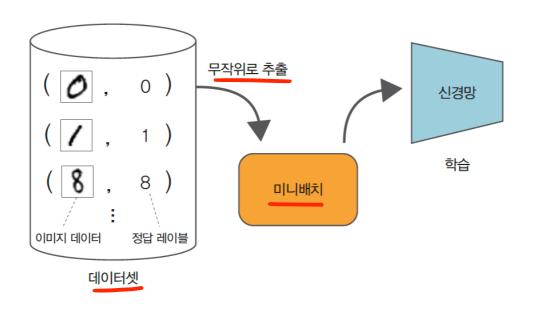
while not done: # 에피소드가 끝날 때까지 반복
env.render() # 진행 과정 시각화
action = np.random.choice([0, 1]) # 행동 선택(무작위)
next_state, reward, terminated, truncated, info = env.step(action)
done = terminated | truncated # 둘 중 하나만 True면 에피소드 종료
env.close()
```

#### C.position C.velocity P.angle P.velocity



# Experience Replay

- 신경망 학습 방법: Training Data Set
  - Supervised learning
    - Training data set 에서 일부 데이터 무작위 추출 ⇒ mini-batch
    - Mini-batch 를 이용해 신경망 학습



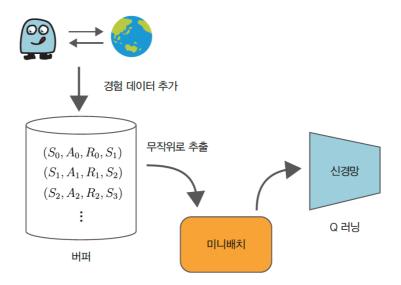
## Experience Replay

- Experience Replay
  - Q Learning G-Net Work
    - Agent 가 환경 속에서 어떤 행동을 취할 때 마다 경험데이터  $E_t$  를 생성하고  $E_t = (S_t, A_t, R_t, S_{t+1})$

buffer 에 저장

- Q 함수를 갱신할 때 buffer 로 부터 일부 경험 데이터 무작위 추출 ⇒ minibatch
- Mini-batch 를 사용하여 신경망 학습
  - ⇒ Experience Replay (경험 재생)

 $E_t$  와  $E_{t+1}$  사이의 상관관계 높음  $\rightarrow$  상관관계를 약화시켜 편향이 작은 학습데이터 생성



### • Experience Replay 구현

```
from collections import deque
import random
import numpy as np
limport gym
class ReplayBuffer:
    def __init__(self, buffer_size, batch_size):
        self.buffer = deque(maxlen=buffer_size)
        self.batch_size = batch_size
    def add(self, state, action, reward, next_state, done):
        data = (state, action, reward, next state, done)
        self.buffer.append(data)
    def len (self):
        return len(self.buffer)
    def get batch(self):
        data = random.sample(self.buffer, self.batch_size)
        state = np.stack([x[0]] for x in data])
        action = np.arrav([x[1] for x in data])
        reward = np.arrav([x[2] for x in data])
        next state = np.stack([x[3]] for x in data])
        done = np.arrav([x[4] \text{ for } x \text{ in data}]).astype(np.int32)
        return state, action, reward, next state, done
```

#### 실습 #1 Replay\_buffer.py

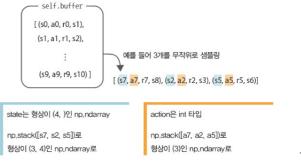
buffer\_size: buffer 최대 크기 batch\_size: mini-batch 크기

deque: 먼저 삽입된 데이터부터 삭제 (선입선출)

버퍼에 경험데이터 추가  $E_t = (S_t, A_t, R_t, S_{t+1})$ 

Buffer 의 크기

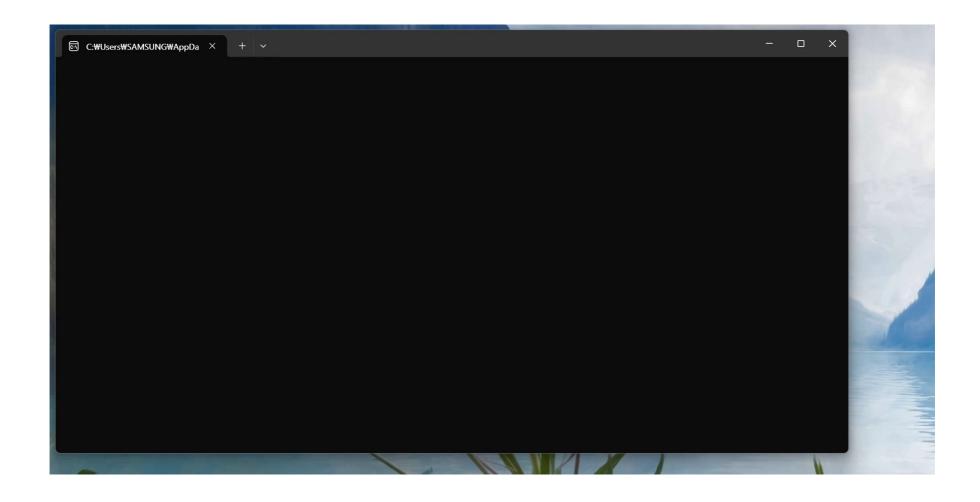
#### Buffer 에 담긴 데이터에서 mini-batch 생성



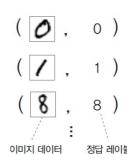
Experience Replay 구현

실습 #1 Replay\_buffer.py

```
env = gym.make('CartPole-v0', render_mode='human')
replay buffer = ReplayBuffer(buffer size=10000, batch size=32)
for episode in range(10): # 에피소드 10회 수행
   state = env.reset()[0]
   done = False
   while not done:
       action = 0 # 항상 0번째 행동만 수행
       next_state, reward, terminated, truncated, info = env.step(action) # 경험 데이터 획득
       done = terminated | truncated
       replay_buffer.add(state, action, reward, next_state, done) # 버퍼에 추가
       state = next_state
# 경험 데이터 버퍼로부터 미니배치 생성
state, action, reward, next_state, done = replay_buffer.get_batch()
print(state.shape)
                       # (32, 4)
print(action.shape)
                       # (32.)
print(reward.shape)
                       # (32,)
print(next_state.shape) # (32, 4)
print(done.shape)
                       # (32.)
```



- 신경망 학습 방법: 정답 Labelling
  - Supervised learning
    - 학습 데이터에 정답 레이블 부여
    - 정답 레이블은 영구적으로 고정됨



- Q Network
  - $Q(S_t, A_t)$  의 목표값 =  $R_t + \gamma \max_a Q(S_{t+1}, a)$ : 정답 레이블
  - Q 값이 갱신될 때마다 정답 레이블이 변경됨
    - → 신경망 학습 어려움
    - ⇒ Target Network (목표 신경망) 을 사용하여 목표값을 고정

#### ❖ Target Network

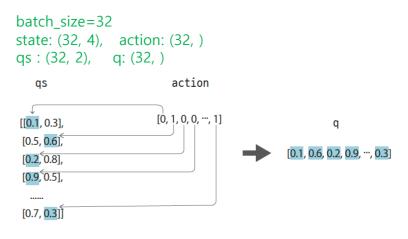
- 원본 신경망 (qnet) 과 구조가 같은 신경망 (qnet\_target)
- qnet 은 일반적인 Q Network 으로 가중치 갱신
- qnet\_target 은 <u>주기적으</u>로 qnet 의 가중치와 동기화시키고, 그 외에는 가중치 고정
- 이후 qnet\_target 을 이용하여 목표값 계산
- ⇒ 정답 레이블이 계속 바뀌는 것을 억제하여 신경망 학습 안정화

• Target Network 구현

```
self.batch size = 32
                                                                                           # 미니배치 크기
import copy
                                                                  self.action_size = 2
from dezero import Model
from dezero import optimizers
                                                                  self.replay_buffer = ReplayBuffer(self.buffer_size, self.batch_size)
import dezero functions as F
                                                                  self.qnet = QNet(self.action_size)
                                                                                                            # 🙆 원본 신경망
import dezero, layers as L
                                                                  self.qnet_target = QNet(self.action_size) # @ 목표 신경망
                                                                   self.optimizer = optimizers.Adam(self.lr)
class QNet(Model): # ● 신경망 클래스
                                                                  self.optimizer.setup(self.gnet)
                                                                                                            # @ 옵티마이저에 qnet 등록
   def init_(self, action_size):
                                                                                                                가중치 업데이트는 qnet 만
        super().__init__()
                                                               def sync qnet(self): # @ 두 신경망 동기화
       self.l1 = L.Linear(128)
                                                                                                                 깊은복사
                                                                  self.qnet target = copy.deepcopy(self.qnet)
        self.12 = L.Linear(128)
        self.13 = L.Linear(action_size)
                                                               def get action(self, state):
                                                                   if np.random.rand() < self.epsilon:</pre>
   def forward(self, x):
                                                                      return np.random.choice(self.action_size)
        x = F.relu(self.l1(x))
                                                                   else:
        x = F.relu(self.12(x))
                                                                      state = state[np.newaxis, :] # 배치 처리용 차원 추가
        x = self.13(x)
                                                                       gs = self.gnet(state)
        return x
                                                                       return qs.data.argmax()
class DQNAgent: # 에이전트 클래스
    def init (self):
        self.gamma = 0.98
        self lr = 0.0005
        self,epsilon = 0.1
        self.buffer size = 10000 # 경험 재생 버퍼 크기
```

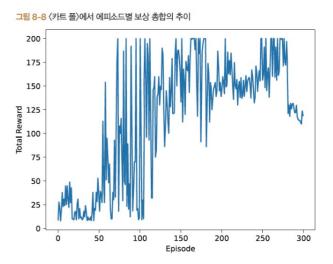
• Target Network 구현

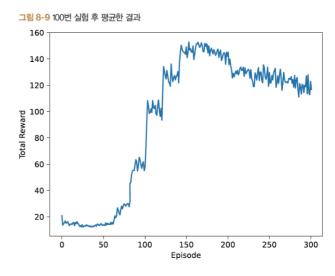
```
class DQNAgent:
   def update(self, state, action, reward, next_state, done):
       # 6 경험 재생 버퍼에 경험 데이터 추가
       self.replay_buffer.add(state, action, reward, next_state, done)
       if len(self.replay buffer) < self.batch size:</pre>
           return # 데이터가 미니배치 크기만큼 쌓이지 않았다면 여기서 끝
        # 🚳 미니배치 크기 이상이 쌓이면 미니배치 생성
       state, action, reward, next_state, done = self.replay_buffer.get_batch()
       qs = self.qnet(state) # @
       q = qs[np.arange(self.batch_size), action] # @
       next_qs = self.qnet_target(next_state)
       next_q = next_qs.max(axis=1)
        next q.unchain()
       target = reward + (1 - done) * self.gamma * next_q # 1
       loss = F.mean squared error(q, target)
       self.gnet.cleargrads()
        loss.backward()
        self.optimizer.update()
```



### DQN 학습

```
# 에피소드 수
episodes = 300
sync interval = 20 # 신경망 동기화 주기(20번째 에피소드마다 동기화)
env = gym.make('CartPole-v0', render_mode='rgb_array')
agent = DQNAgent()
reward_history = [] # 에피소드별 보상 기록
for episode in range(episodes):
    state = env.reset()[0]
    done = False
   total_reward = 0
    while not done:
        action = agent.get_action(state) \epsilon greedy
        next_state, reward, terminated, truncated, info = env.step(action)
        done = terminated | truncated
        agent.update(state, action, reward, next_state, done)
        state = next state
        total_reward += reward
    if episode % sync_interval == 0:
        agent.sync_qnet()
                                         Target network 동기화
    reward history.append(total_reward)
```





### DQN

### • DQN 실행

```
agent.epsilon = 0 # 탐욕 정책(무작위로 행동할 확률 8을 0으로 설정)

state = env.reset()[0]

done = False

total_reward = 0

while not done:
    action = agent.get_action(state)
    next_state, reward, terminated, truncated, info = env.step(action)
    done = terminated | truncated
    state = next_state
    total_reward += reward
    env.render()

print('Total Reward:', total_reward)
```

Total Reward: 116

#### 실습 #2 dqn2.py

```
import copy
from collections import deque
import random
import matplotlib.pvplot as plt
import numpy as no
import gym
from dezero import Model
from dezero import optimizers
import dezero.functions as F
import dezero. Lavers as L
class ReplayBuffer:
    def __init__(self, buffer_size, batch_size):
        self.buffer = deque(maxlen=buffer_size)
        self.batch size = batch size
    def add(self. state, action, reward, next_state, done):
        data = (state, action, reward, next state, done)
        self.buffer.append(data)
    def len (self):
        return len(self.buffer)
    def get batch(self):
        data = random.sample(self.buffer. self.batch size)
        state = np.stack([x[0]] for x in data])
        action = np.arrav([x[1] \text{ for } x \text{ in data}])
        reward = np.arrav([x[2] for x in data])
        next_state = np.stack([x[3] for x in data])
        done = np.array([x[4] for x in data]).astvpe(np.int32)
        return state, action, reward, next_state, done
```

```
class QNet(Model): # 신경망 클래스
   def __init__(self, action_size):
       super().__init__()
       self.I1 = L.Linear(128)
       self.12 = L.Linear(128)
       self.13 = L.Linear(action_size)
   def forward(self, x):
       x = F.relu(self.11(x))
       x = F.relu(self.12(x))
       x = self.13(x)
       return x
class DQNAgent: # 에이전트 클래스
   def init (self):
       self.gamma = 0.98
       self.Ir = 0.0005
       self.epsilon = 0.1
       self.buffer_size = 10000 # 경험 재생 버퍼 크기
       self.batch size = 32
                                # 미니배치 크기
       self.action size = 2
       self.replay_buffer = ReplayBuffer(self.buffer_size, self.batch_size)
       self.gnet = QNet(self.action_size)
                                                # 원본 신경망
       self.gnet target = QNet(self.action size) #목표 신경망
       self.optimizer = optimizers.Adam(self.lr)
                                                # 옵티마이저에 anet 등록
       self.optimizer.setup(self.gnet)
   def get_action(self, state):
       if np.random.rand() < self.epsilon:</pre>
           return np.random.choice(self.action size)
       else
           state = state[np.newaxis, :] # 배치 처리용 차원 추가
           as = self.anet(state)
           return qs.data.argmax()
```

```
def update(self, state, action, reward, next state, done):
       # 경험 재생 버퍼에 경험 데이터 추가
       self.replay buffer.add(state, action, reward, next state, done)
       if len(self.replay buffer) < self.batch size:</pre>
          return # 데이터가 미니배치 크기만큼 쌓이지 않았다면 여기서 끝
       # 미니배치 크기 이상이 쌓이면 미니배치 생성
       state, action, reward, next state, done = self.replay_buffer.get_batch()
       gs = self.gnet(state)
       g = gs[np.arange(self.batch size), action]
       next_qs = self.qnet_target(next_state)
       next q = next qs.max(axis=1)
       next q.unchain()
       target = reward + (1 - done) * self.gamma * next q
       loss = F.mean squared error(q, target)
       self.gnet.cleargrads()
       loss.backward()
       self.optimizer.update()
   def sync gnet(self): # 두 신경망 동기화
       self.qnet_target = copy.deepcopy(self.qnet)
                 # 에피소드 수
episodes = 300
sync_interval = 20 # 신경망 동기화 주기(20번째 에피소드마다 동기화)
env = gym.make('CartPole-v0', render mode='rgb array')
agent = DQNAgent()
reward history = [] # 에피소드별 보상 기록
```

```
for episode in range(episodes):
   state = env.reset()[0]
   done = False
   total reward = 0
   while not done:
       action = agent.get action(state)
       next state, reward, terminated, truncated, info = env.step(action)
       done = terminated | truncated
       agent.update(state, action, reward, next state, done)
       state = next state
       total reward += reward
   if episode % sync interval == 0:
       agent.sync qnet()
   reward history.append(total reward)
   if episode % 10 == 0:
       print("episode :{}, total reward : {}".format(episode, total_reward))
# 카트 폴」에서 에피소드별 보상 총합의 추이
plt.xlabel('Episode')
plt.ylabel('Total Reward')
plt.plot(range(len(reward history)), reward history)
plt.show()
# 학습이 끝난 에이전트에 탐욕 행동을 선택하도록 하여 플레이
env2 = gym.make('CartPole-v0', render_mode='human')
agent.epsilon = 0 # 탐욕 정책(무작위로 행동할 확률 ε을 0로 설정)
state = env2.reset()[0]
done = False
total reward = 0
while not done:
   action = agent.get action(state)
   next state, reward, terminated, truncated, info = env2.step(action)
   done = terminated | truncated
   state = next state
   total reward += reward
   env2.render()
print('Total Reward:', total_reward)
```

Hyper-Parameter

```
할인율 (gamma = 0.98)
학습률 (Ir = 0.0005)
ε-탐욕 확률 (epsilon = 0.05)
경험 재생 버퍼 크기 (buffer_size = 100000)
미니배치 크기 (batch_size = 32)
에피소드 수 (episodes = 300)
동기화 주기 (sync_interval = 20)
신경망 구조 (계층 수, Linear 계층의 노드 수 등)
```

```
    C:₩Users₩SAMSUNG₩AppDa ×

         C:\Users\SAMSUNG\AppData\Local\Programs\Python\Python39\lib\site-packages\gym\envs\registration.py:555: UserWarning: WAR
N: The environment CartPole-v0 is out of date. You should consider upgrading to version `v1`.
         logger.warn(
episode :0, total reward : 9.0
episode :10, total reward : 22.0
episode :20, total reward : 11.0
DΚ
el LDK
```

### Mountain Car

#### Environment

State (observation)

Num	Observation	Min	Max	Unit
0	position of the car along the x-axis	-1.2	0.6	position (m)
1	velocity of the car	-0.07	0.07	velocity (v)

Action

0: Accelerate to the left

1: Don't accelerate

2: Accelerate to the right



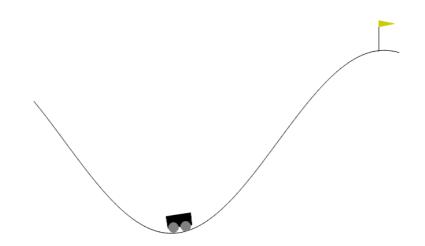
- Rewards
  - -1 for each time step (goal is to reach the flag as quickly as possible)
- Starting state
  - Position if the car: uniformly random value in [-0.6, -0.4]
- Episode ends if any one of the following occurs
  - 1. Termination: The position of the car is greater than or equal to 0.5 (the goal position on top of the right hill)
  - 2. Truncation: The length of the episode is 200.

### Quiz

(Q1) DQN 을 Mountain Car 문제에 적용하되, Hyper-parameter 를 변경하여 최대의 total reward 를 갖는 policy 를 결정하라.

#### (제출물: PPT)

- 1) 최적 hyperparameter
- 2) Episode 별 total reward graph
- 3) 최대 total reward 값 및 해당 policy 적용 시의 동영상



### Double DQN

- DQN 의 Overfitting 문제
  - TD Target

$$R_t + \gamma \max_a Q(S_{t+1}, a)$$

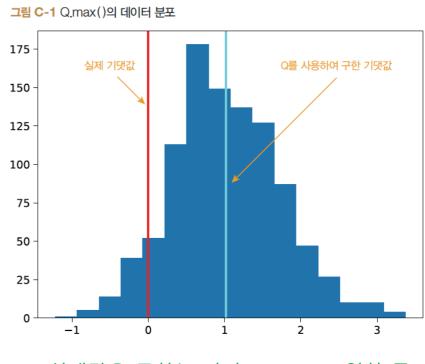
- Estimation of TD Target (Network)
  - Original network:  $\theta \to R_t + \gamma \max_a Q_{\theta}(S_{t+1}, a)$
  - Target network:  $\theta' \to R_t + \gamma \max_a Q_{\theta'}(S_{t+1}, a)$
- Overfitting (과대적합) 문제
  - $\max_{a} Q_{\theta}(S_{t+1}, a)$  : training data 에 overfitting 가능

(ex) 
$$q(s, a_0) = q(s, a_1) = q(s, a_2) = q(s, a_3) = 0$$
=> 계산값:  $\mathbb{E}\left[\max_a q(s, a)\right] = 0$ 
=> 추정값:  $\mathbb{E}\left[\max_a Q(s, a)\right] > 0$  (Q: 정규분포 데이터)

### Double DQN

• DQN 의 Overfitting 문제

```
import numpy as np
import matplotlib.pyplot as plt
samples = 1000
action size = 4
Qs = []
for in range(samples):
   # 정규분포에서 생성한 무작위 수를 노이즈로 추가
Q = np.random.randn(action size)
   Qs.append(Q.max())
# 히스토그램으로 시각화
plt.hist(Qs, bins=16)
plt.axvline(x=0, color='red')
plt.axvline(x=np.array(Qs).mean(), color='cyan')
plt.show()
```

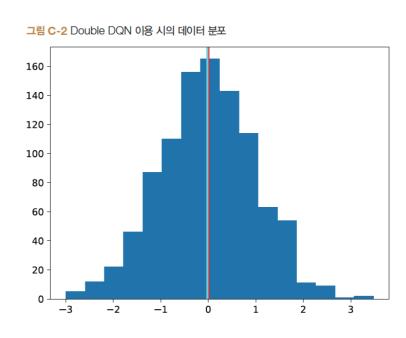


최대값을 구하는 것이므로 noise 영향 큼

### Double DQN

- DQN 의 Overfitting 해결방법
  - 두 개의 독립적 Q 함수 사용: Q & Q\_prime ⇒ double DQN
    - 최대 행동 선택 시: Q 사용
    - 선택된 행동에 대한 Q 값 : Q\_prime 사용

```
import numpy as np
import matplotlib.pyplot as plt
samples = 1000
action size = 4
Qs = []
for in range(samples):
   Q = np.random.randh(action_size)
   Q_prime = np.random.randn(action_size) # 또 다른 Q 함수
   idx = np,argmax(Q) # Q에서 최대 행동 선택
   Qs.append(Q_prime[idx]) # 선택된 행동에 대한 값을 Q_prime에서 구함
# 히스토그램으로 시각화
plt.hist(Qs, bins=16)
plt.axvline(x=0, color='red')
plt.axvline(x=np.array(Qs),mean(), color='cyan')
plt.show()
```



# Prioritized Experience Replay

- Experience Replay
  - 경험 데이터  $E_t = (S_t, A_t, R_t, S_{t+1})$  를 buffer 에 저장 => 학습 시 무작위로 추출하여 사용
- Prioritized Experience Replay (PER)
  - 경험 데이터에 학습 Loss 값 포함
    - $\delta_t = \left| \begin{array}{c|c} R_t + \gamma & \max_a Q_{\theta'}(S_{t+1}, a) Q_{\theta}(S_{t}, a) \end{array} \right|$  : loss  $\delta_t$  가 큰 경우 : 수정할 것이 많음 -> 학습 시킬 것이 많음  $\delta_t$  가 작은 경우 : 수정할 것이 적음 -> 학습 시킬 것이 적음
    - 경험 데이터  $E_t = (S_t, A_t, R_t, S_{t+1}, \frac{\delta_t}{\delta_t})$
  - 경험데이터 선택 시 우선순위를 고려하여 추출 ⇒ 학습속도 향상
    - 선택확률

$$p_i = \frac{\delta_i}{\sum_{k=0}^N \delta_k}$$

S. Tom et. al., "Prioritized experience replay", arXiv, 2015.

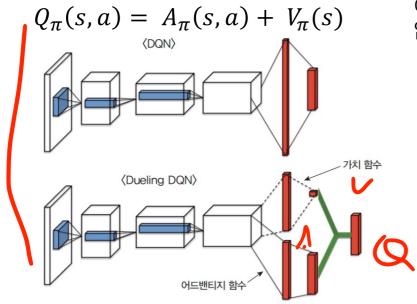
# Dueling DQN

### Advantage Function

Dueling = competing

- Q 함수 (action value) 와 V 함수 (state value) 의 차이
- $A_{\pi}(s, a) = Q_{\pi}(s, a) V_{\pi}(s)$ 
  - $Q_{\pi}(s,a)$ : 상태 s에서 '특정 행동 a'를 취하고 그 이후에는  $\pi$ 에 따라 행동했을 때 얻을 수 있는 기대 수익
  - $V_\pi(s)$ : 상태 s에서 이후의 모든 행동을 정책  $\pi$ 에 따라 했을 때 얻을 수 있는 기대 수익

### Dueling DQN



어떤 행동(action) 을 선택해도 결과가 달라지지 않는 상황

- DQN : 학습 진행되지 않음

- Dueling DQN: V 함수로 Q 근사 학습 진행 학습속도 향상 기대

