딥러닝
Deep Learning

이건명
충북대학교 대학원 산업인공지능학과

학습 내용

- 딥러닝 신경망의 특성에 대해서 알아본다.
- 기울기 소멸 문제와 해결 방안에 대해서 알아본다.
- 가중치 초기화 방법에 대해서 알아본다.
- 신경망의 과적합 완화 기법들에 대해서 알아본다.
- 신경망 학습에 사용되는 경사 하강법의 여러가지 변형 형태에 대해서 알아본다.

1. 딥러닝

❖ **딥러닝(deep learning)**
- 비교적 최근에 개발된 **딥러닝 신경망 모델** **기반의 기계 학습 기법**을 차별화하여 일컫는 말
- **다수의 층**을 갖는 **신경망** 구조 사용
- 복잡한 구조의 신경망을 학습시키기 위해 **많은 데이터**와 **많은 컴퓨팅 자원** 사용
- 다양한 분야에서 기존 기계학습 방법보다 **훨씬 뛰어난 성능**을 보이면서 많은 관심

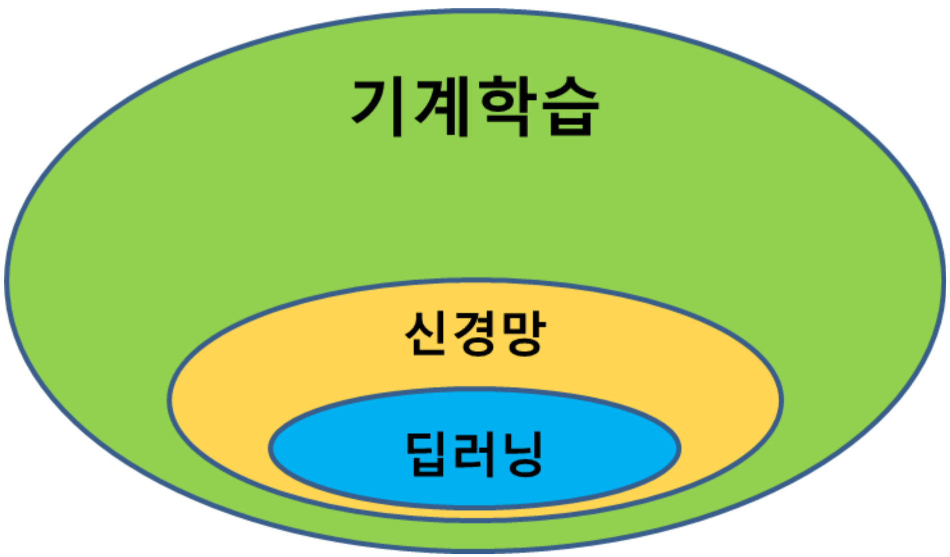

딥러닝

❖ **딥러닝(deep learning)**

- **일반 신경망**
  - **소수의 은닉층 포함**

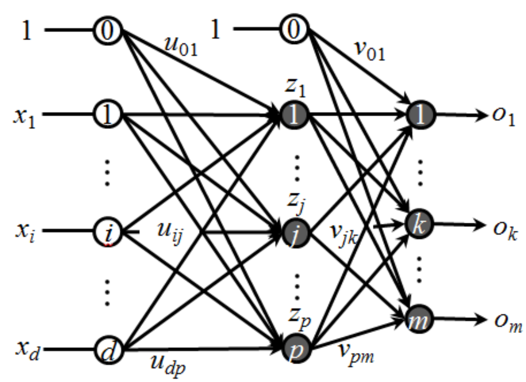

- **딥러닝 신경망 (심층 신경망, deep neural network)**
  - **다수의 은닉층 포함**

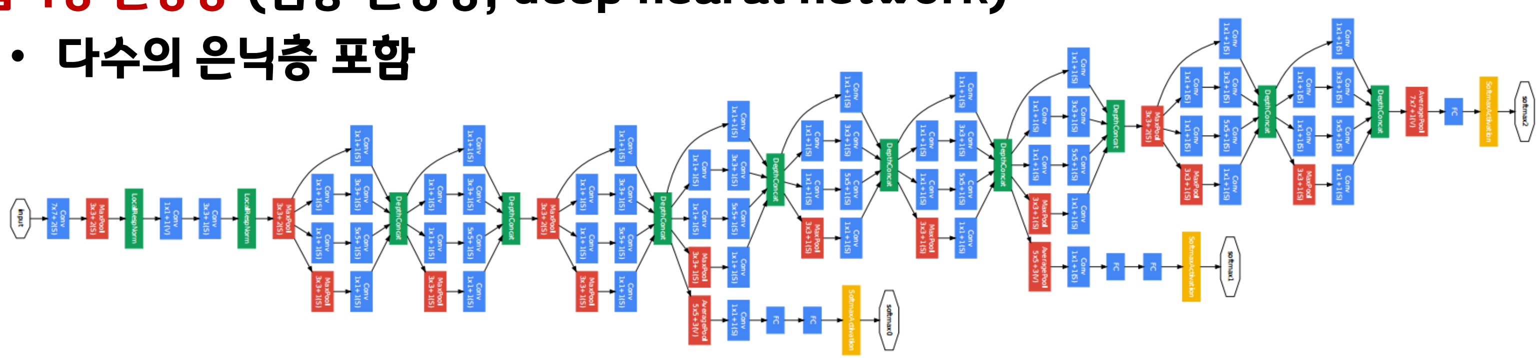

출전: googLeNet (google)

딥러닝

❖ 일반 신경망과 딥러닝 신경망

▪ 일반 신경망 모델

- 원시 데이터(original data)에서 직접 특징(handcrafted feature)을 추출해서 만든 **특징 벡터**(feature vector)를 신경망 모델 학습을 위한 입력으로 사용
- 특징 벡터들의 품질에 영향

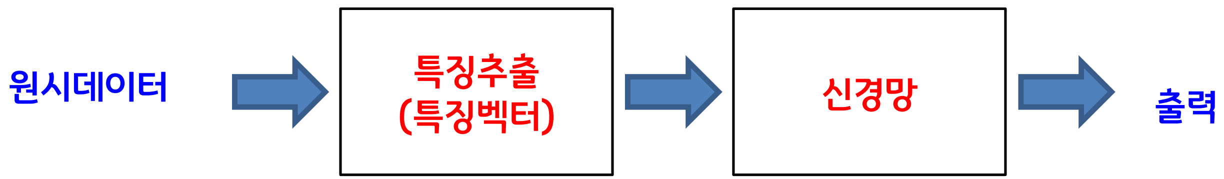

▪ 딥러닝 신경망

- **특징추출**과 **문제 해결을 위한 모델**의 **학습**을 함께 수행
- 데이터로부터 문제해결에 **효과적인 특징**을 학습을 통해 추출
  ➔ 우수한 성능

2. 기울기 소멸 문제

❖ **기울기 소멸 문제(Vanishing gradient problem)**

- 은닉층이 많은 다층 퍼셉트론에서, 출력층에서 아래 층으로 갈 수록 전달되는 오차가 크게 줄어들어, 학습이 되지 않는 현상

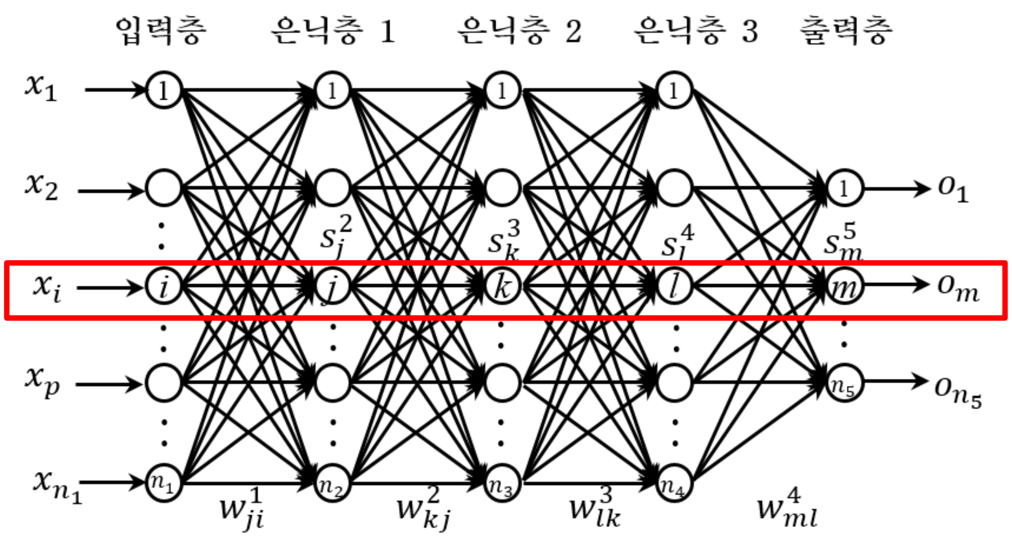

$$E = \frac{1}{2}\sum_{m=1}^{n_5}(y_m - o_m)^2$$

$$\frac{\partial E}{\partial w_{ji}^1} = \sum_{m=1}^{n_5}\sum_{l=1}^{n_4}\sum_{k=1}^{n_3}\sum_{j=1}^{n_2}(y_m - o_m)f'(s_m^5)\,w_{ml}^4 f'(s_l^4)w_{lk}^3 f'(s_k^3)\,w_{kj}^2 f'(s_j^2)\,x_i$$

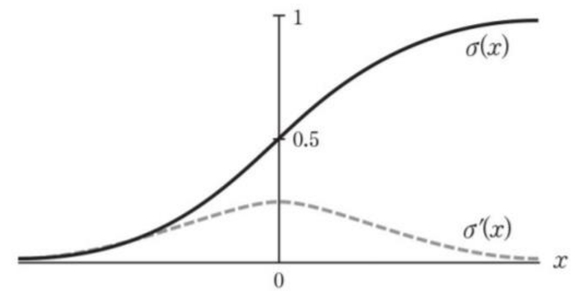

시그모이드(sigmoid)

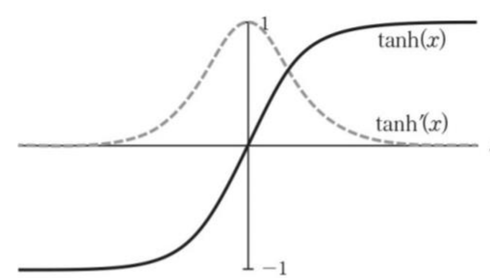

쌍곡 탄젠트(hypertangent)

기울기 소멸 문제

❖ **기울기 소멸 문제 완화**

- 시그모이드나 쌍곡 탄젠트 대신 **ReLU**(Rectified Linear Unit) **함수** 사용

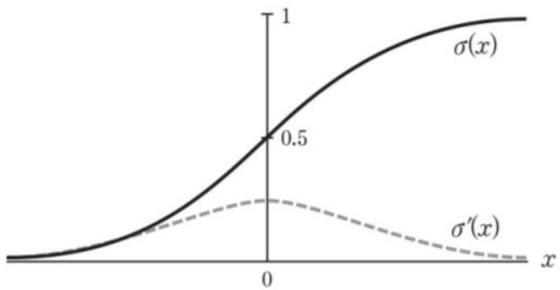

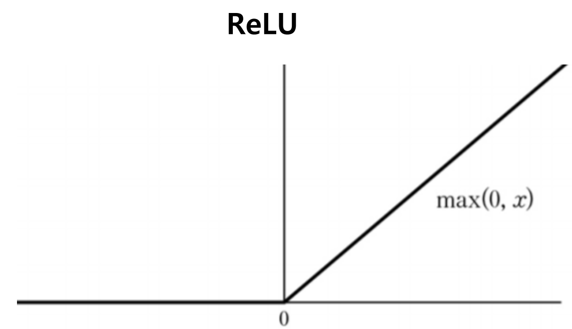


```
def ReLU(x):
    return np.maximum(0,x)
```

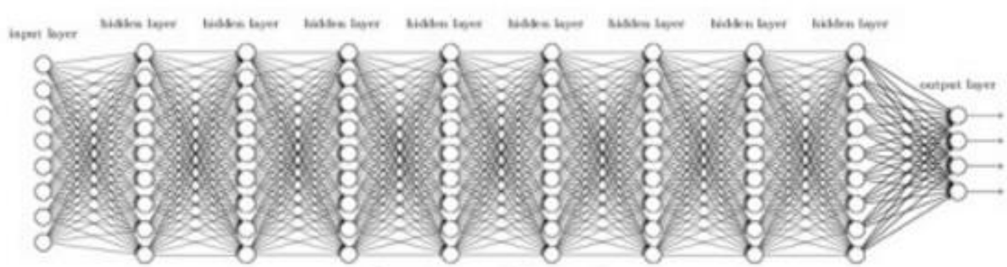

Deep Neural Network

ReLU 사용

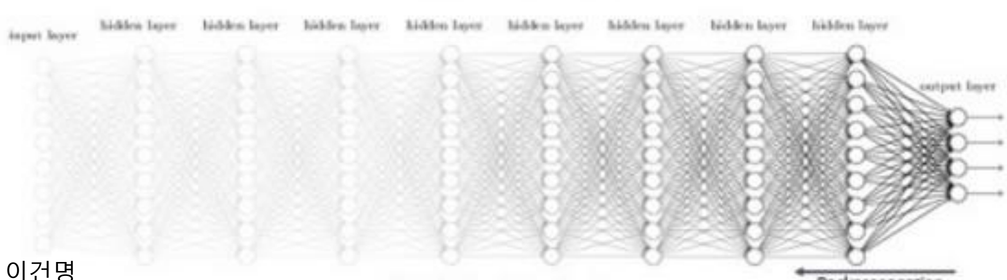

Vanishing Gradient

시그모이드 사용

https://www.kaggle.com/getting-started/118228

기울기 소멸 문제

❖ ReLU 함수 사용과 함수 근사

- 함수를 부분적인 평면 타일들로 근사(approximate)하는 형태
- 출력이 0이상인 것들에 의해 계산되는 결과
  - 입력의 선형변환(입력과 가중치 행렬의 곱으로 표현)의 결과

$$y = [\ ]_{1\times 2} \cdot [\ ]_{2\times 3} \cdot [\ ]_{3\times 2}\, \boldsymbol{x} \qquad\qquad y = [\ ]_{1\times 3} \cdot [\ ]_{3\times 2} \cdot [\ ]_{2\times 2}\, \boldsymbol{x}$$

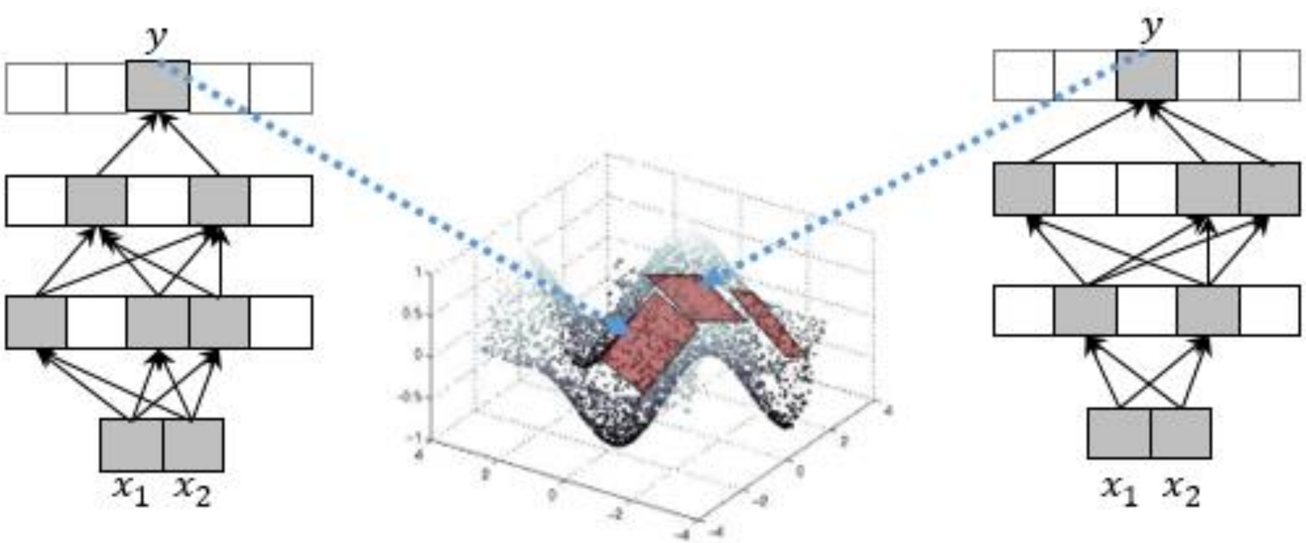

기울기 소멸 문제

❖ ReLU와 변형된 형태의 활성화 함수

ReLU

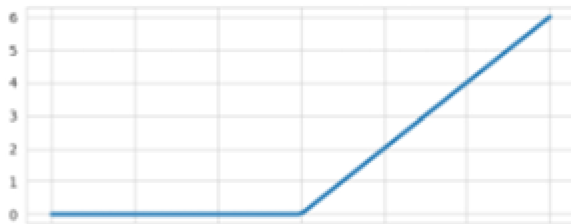

누수 ReLU(Leaky ReLU)

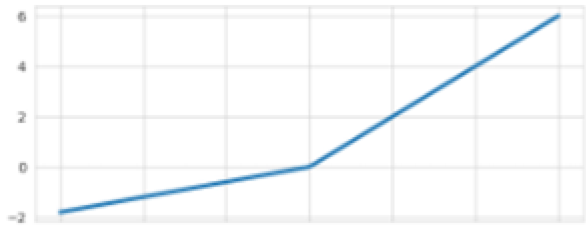

ELU(exponential Linear Unit)

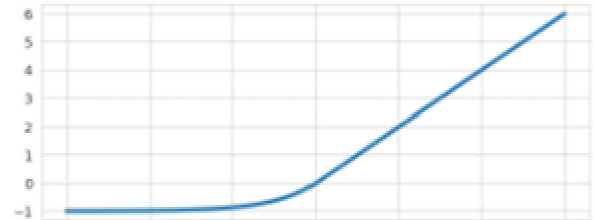

GELU(Gaussian Error Linear Unit)

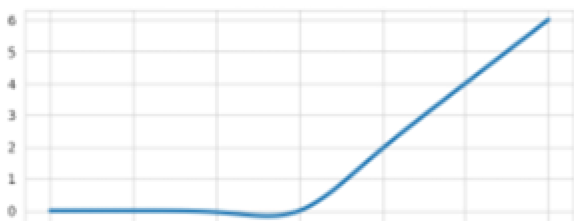

SELU

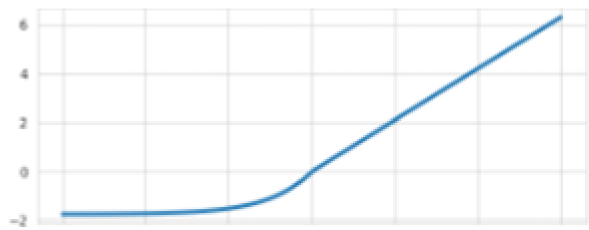

SoftPlus

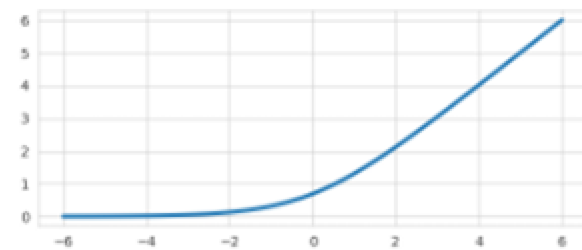

Swish

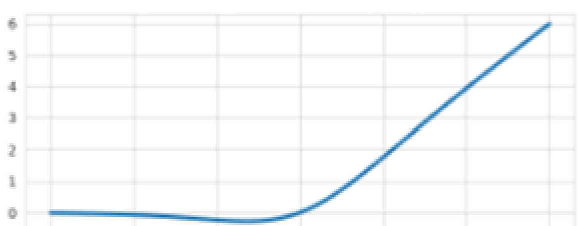

Mish

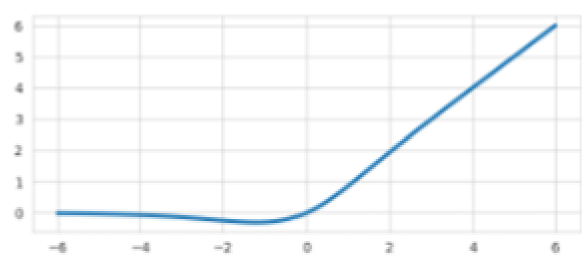

Softmax

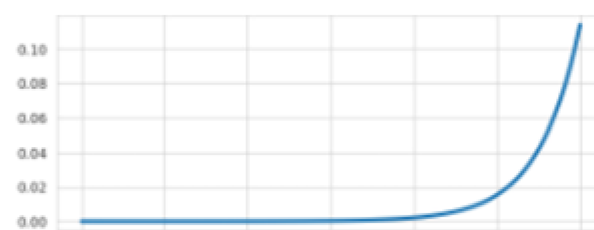

https://ml-explained.com/blog/activation-functions-explained

기울기 소멸 문제

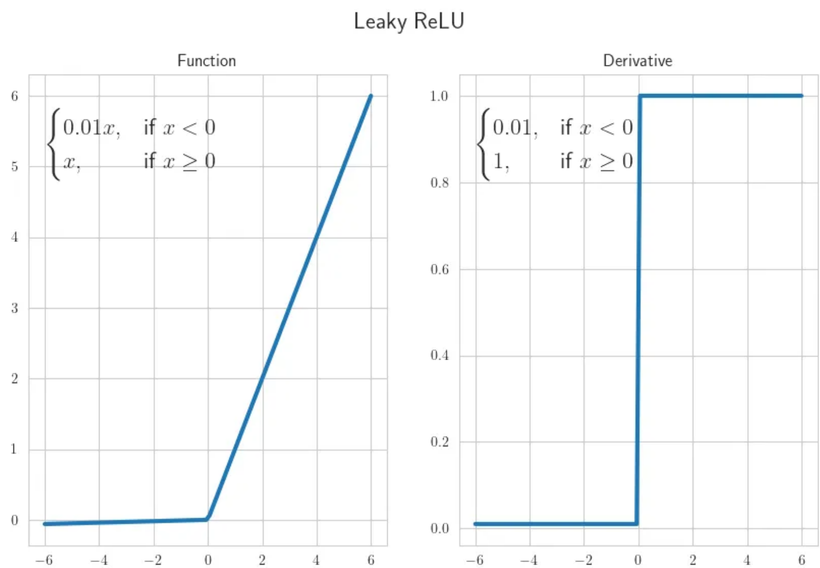
Leaky ReLU
Function
$\begin{cases} 0.01x, & \text{if } x < 0 \\ x, & \text{if } x \geq 0 \end{cases}$
Derivative
$\begin{cases} 0.01, & \text{if } x < 0 \\ 1, & \text{if } x \geq 0 \end{cases}$

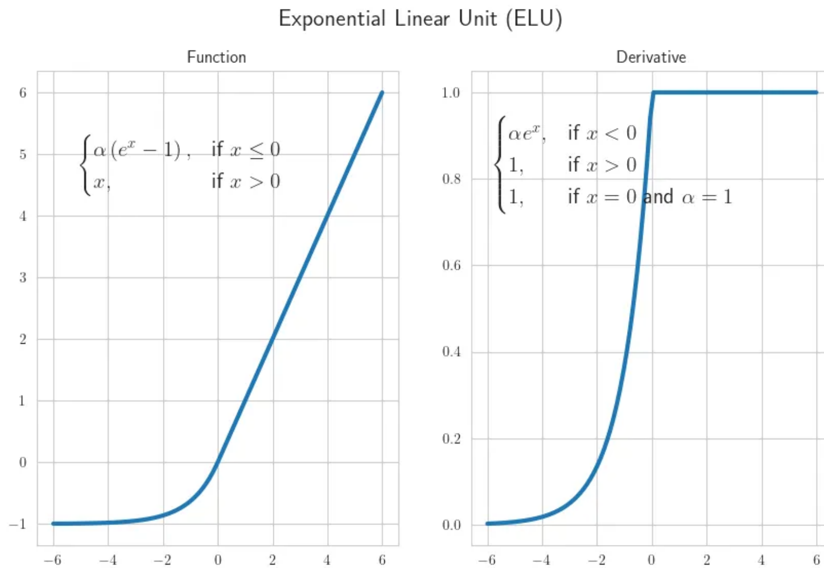
Exponential Linear Unit (ELU)
Function
$\begin{cases} \alpha(e^x - 1), & \text{if } x \leq 0 \\ x, & \text{if } x > 0 \end{cases}$
Derivative
$\begin{cases} \alpha e^x, & \text{if } x < 0 \\ 1, & \text{if } x > 0 \\ 1, & \text{if } x = 0 \text{ and } \alpha = 1 \end{cases}$

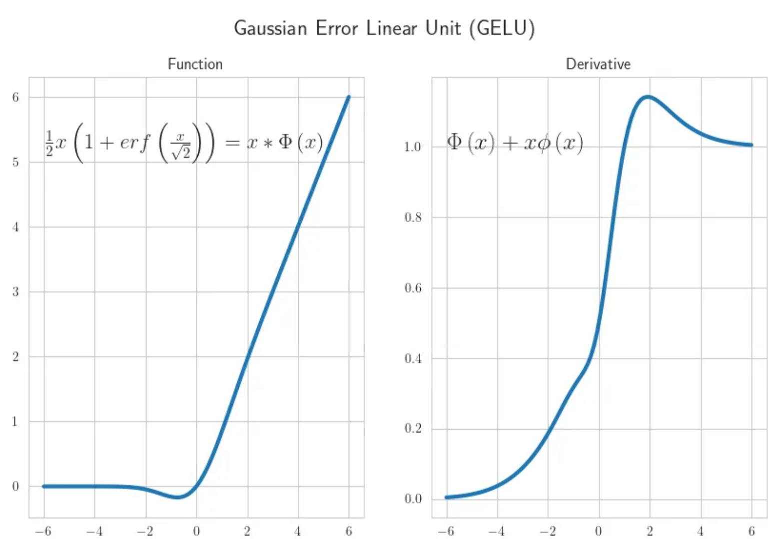
Gaussian Error Linear Unit (GELU)
Function
$\frac{1}{2}x\left(1 + erf\left(\frac{x}{\sqrt{2}}\right)\right) = x * \Phi(x)$
Derivative
$\Phi(x) + x\phi(x)$

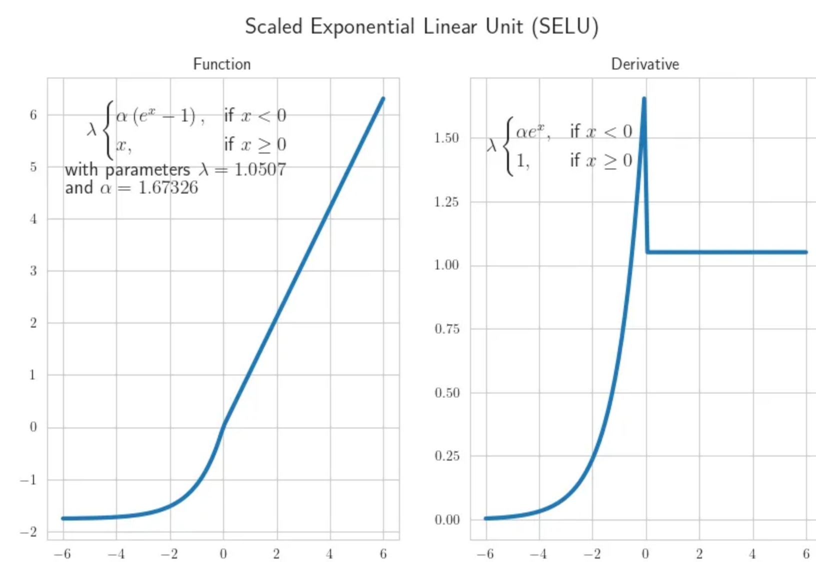
Scaled Exponential Linear Unit (SELU)
Function
$\lambda \begin{cases} \alpha(e^x - 1), & \text{if } x < 0 \\ x, & \text{if } x \geq 0 \end{cases}$
with parameters $\lambda = 1.0507$
and $\alpha = 1.67326$
Derivative
$\lambda \begin{cases} \alpha e^x, & \text{if } x < 0 \\ 1, & \text{if } x \geq 0 \end{cases}$

기울기 소멸 문제

❖ 활성화 함수와 도함수

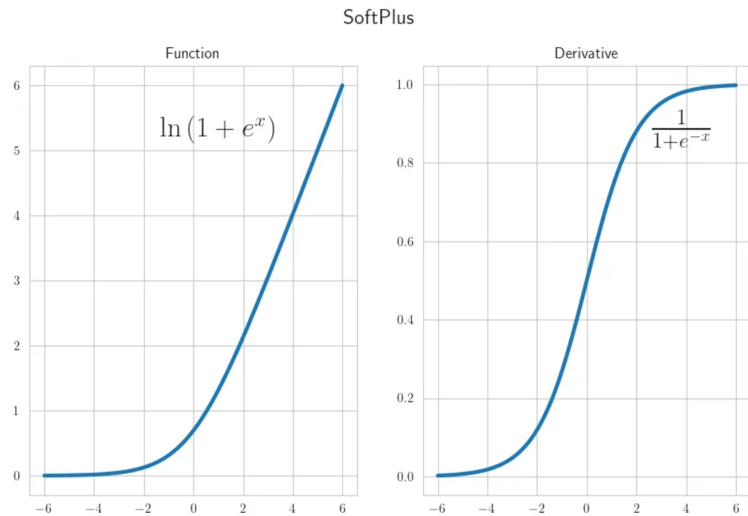

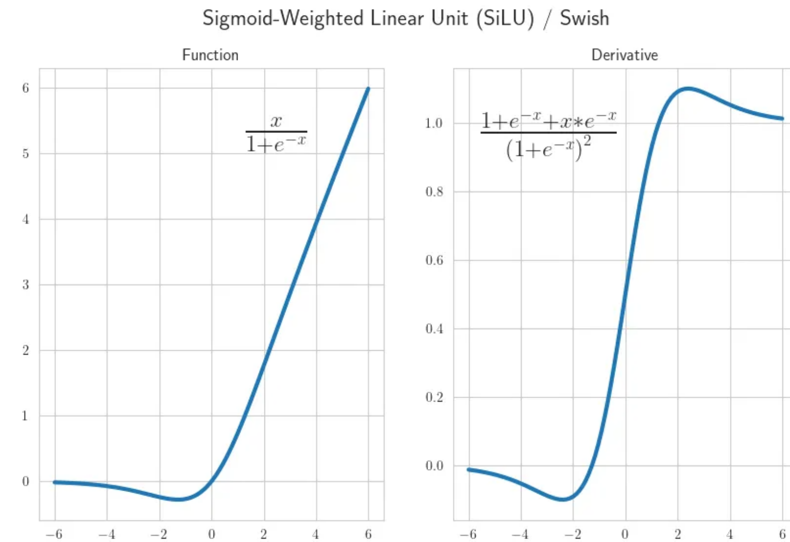

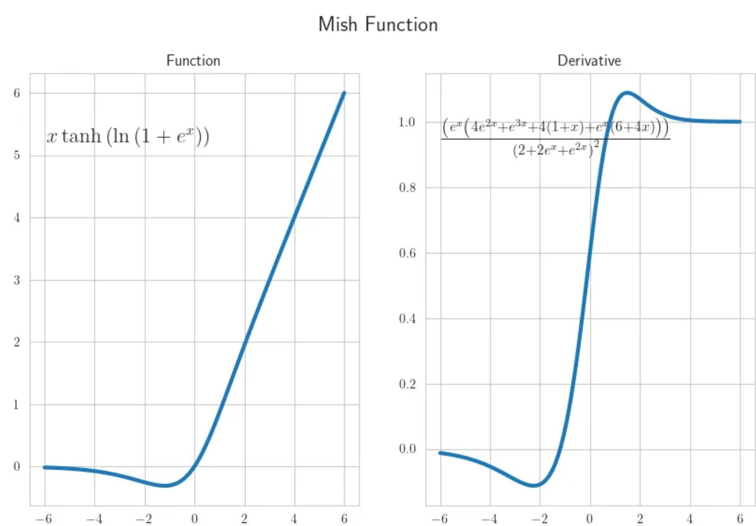

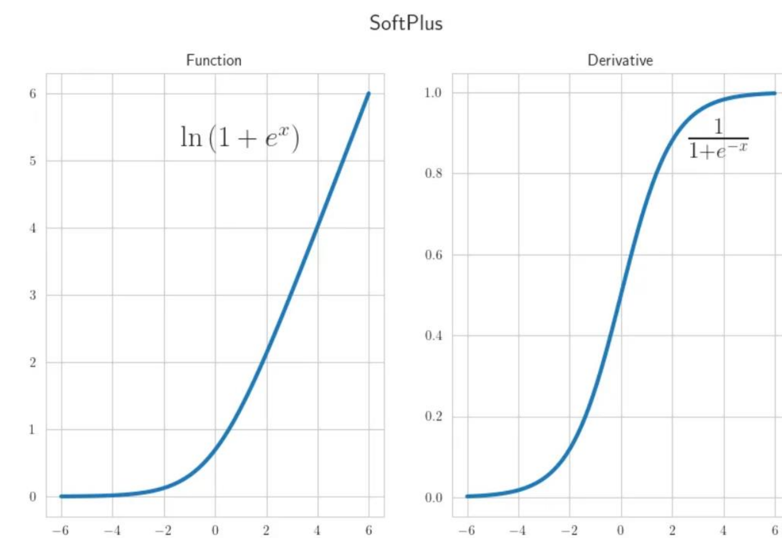

3. 가중치 초기화

❖ **가중치 최기화**

- 신경망의 성능에 큰 영향을 주는 요소
- 보통 가중치의 초기값으로 0에 가까운 무작위 값 사용

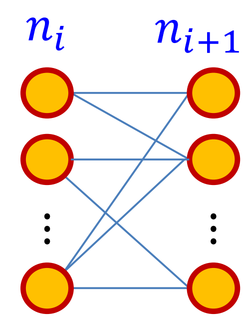

❖ **개선된 가중치 초기화 방법**

- 각 노드의 **입력 노드 개수** n_i와 **출력 노드의 개수** n_{i+1}를 사용하는 방법
  - **균등 분포 초기화**

$$U\left[-\sqrt{\frac{6}{n_i+n_{i+1}}},\ \sqrt{\frac{6}{n_i+n_{i+1}}}\right]$$에서 무작위로 선택

```
sd = np.sqrt(6/(layer_size[i+1]+ layer_size[i]))
W = np.random.uniform(-sd, sd, layer_size[i]*
      layer_size[i-1]).reshape(layer_size[i+1], layer_size[i])
```

  - **제이비어(Xavier) 초기화**

$$\frac{N(0,1)}{\sqrt{n_i}}$$ 에서 무작위로 선택

$N(0,1)$: 표준 정규분포

```
W = np.random.randn(layer_size[i+1], layer_size[i])
      * np.sqrt(1/layer_size[i])
```

  - **허(He) 초기화**

$$\frac{N(0,1)}{\sqrt{n_i/2}}$$에서 무작위로 선택

```
W = np.random.randn(layer_size[i+1], layer_size[i])
      * np.sqrt(2/layer_size[i])
```

4. 과적합 문제

❖ 과적합(Overfitting)

- 모델이 학습 데이터에 지나치게 맞추어진 상태
- 데이터에는 잡음이나 오류가 포함
  - 과적합된 모델은 학습되지 않는 데이터에 대해 성능 저하

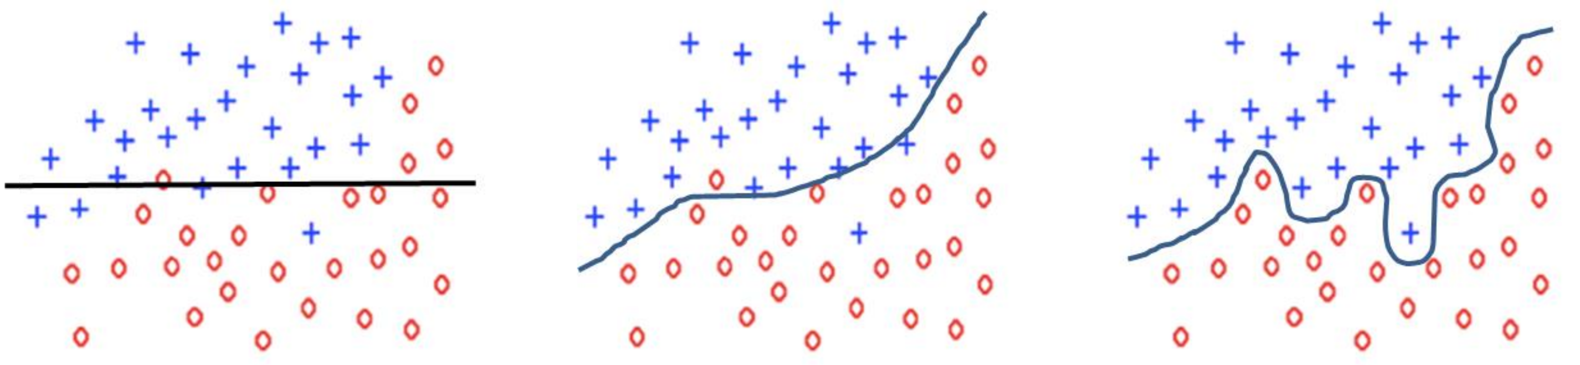

부적합(underfitting) 정적합(good fitting) 과적합(overfitting)

- 과적합 문제 완화 기법
  - 규제화
  - 드롭아웃
  - 배치 정규화

과적합 문제

1. 규제화(Regularization) 기법

- 오차 함수를 오차(error) 항과 모델 복잡도(model complexity) 항으로 정의
  - 모델이 복잡해 지면 과적합이 될 수 있으므로, 모델 복잡도를 벌점(penalty) 항으로 추가

오차 함수= (오차 항) +α(모델 복잡도 항)

α : 상대적인 반영비율을 조정

- **신경망 학습의 모델 복잡도**
  - 절대값이 큰 가중치에 **벌점**(penalty) 부여

$$\boldsymbol{w} = (w_1, w_2, \cdots, w_n)$$

  - 모델 복잡도 정의

$$\sum_{i=1}^{n} w_i^2 \quad \text{또는} \quad \sum_{i=1}^{n} |w_i|$$

cf. ridge/lasso regression

과적합 문제

2. 드롭아웃(Dropout) 기법

- **학습**할 때 일정 확률로 노드들을 무작위로 선택하여, **선택된 노드의 앞뒤로 연결된 가중치 연결선은 없는 것으로** 간주
- **미니배치**(mini-batch)나 **학습주기**(epoch) 마다 드롭아웃 할 즉, 없는 것으로 간주할 노드들을 새롭게 선택하여 학습
- **추론**을 할 때는 드롭아웃을 하지 않고 **전체 학습된 신경망을 사용**하여 출력 계산

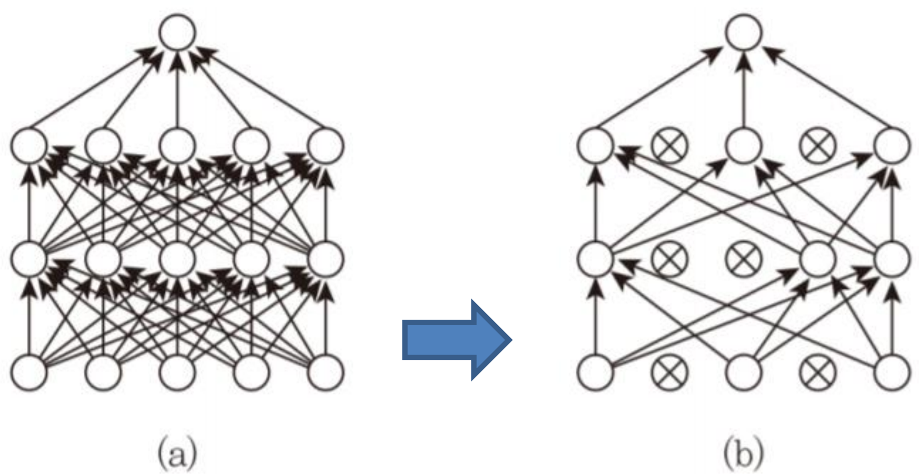

그림 5.6 드롭아웃 방법

(b)는 (a)의 신경망에 드롭아웃을 적용한 결과를 나타냄

과적합 문제

- ❖ **학습주기(epoch, 에포크)**
  - ▪ **전체 데이터**에 대해서 신경망 모델을 **한번의 학습 과정**을 완료하는 것

- ❖ **배치(batch)**
  - ▪ 신경망의 **가중치를 한번 수정**할 때 **사용**되는 **데이터**
  - ▪ **배치 크기(batch size)**
    - **하나의 배치**에 **포함**되는 **데이터의 개수**

- ❖ **iteration(반복)**
  - ▪ **한 번의 학습주기**를 **완료**하기 위해 수행되는 **배치**의 **처리 회수**
    - **iteration 개수 = (전체 데이터 개수)/(배치 크기)**

과적합 문제

❖ **학습 데이터 단위에 따른 가중치 갱신 전략**

- **확률적 갱신 (stochastic update, stochastic gradient descent)**
  - 한번에 **하나의 학습 데이터**에 대한 **그레디언트**를 계산하여 가중치 갱신
  - 가중치의 변동이 심하여 성능 개선 저하
- **배치 갱신 (batch update, batch gradient descent)**
  - **전체 학습 데이터**에 대한 **그레디언트의 평균**을 구하여 가중치 갱신
  - 느린 학습
- **미니배치 갱신 (mini-batch update, mini-batch gradient descent)**
  - **일정 개수의 학습 데이터**, **미니배치**에 대해 그레디언트의 평균을 구하여 가중치 갱신
    - 예. 10개 데이터로 구성된 미니배치의 그레디언드

$$\nabla g = \frac{1}{10}\sum_{i=1}^{10} \nabla g_i$$

  - 과적합 문제 완화에 도움

배치 vs 미니배치

❖ 가중치 갱신 단위

- 그레디언트 계산 단위

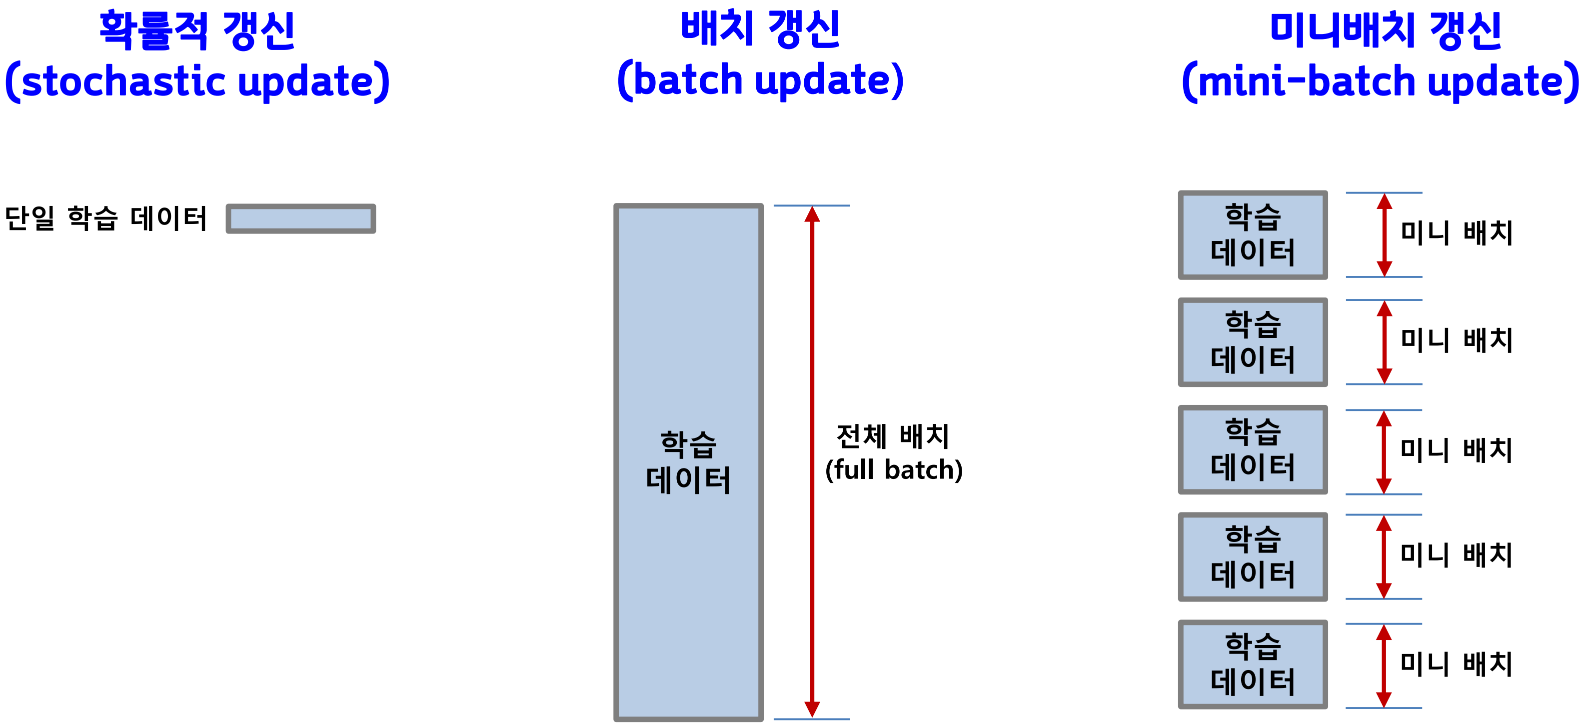

배치 vs 미니배치

❖ 확률적 갱신

```
for i in range(m):      # m: 에포크 수
    for one_data in training_data:
        gradient = evaluate_gradient(one_data)
        weight = weight – learning_rate * gradient
```

❖ 미니배치 갱신

```
for i in range(m):
    for one_batch in get_mini_batches(training_data, one_batch_size=32):
        gradient = evaluate_gradient(one_batch)
        weight = weight – learning_rate * gradient
```

❖ 배치 갱신

```
for i in range(m):
    gradient = evaluate_gradient(training_data)
    weight = weight – learning_rate * gradient
```

과적합 문제

3. 배치 정규화(Batch normalization) 기법

- **내부 공변량 이동(internal covariate shift) 문제**
  - 오차 역전파 알고리즘 적용 학습
  - 이전 층들의 학습에 의해 이들 층의 가중치가 바뀌게 되면, 현재 층에 전달되는 데이터의 분포가 현재 층이 학습했던 시점의 분포와 차이 발생 ➔ 학습 속도 저하

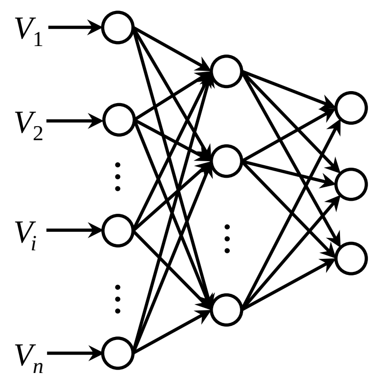

- **배치 정규화**
  - 신경망의 **각 층**에서 **미니배치** B의 각 데이터에 가중치 연산을 적용한 결과인 x_i의 **분포**를 **정규화**하는 것

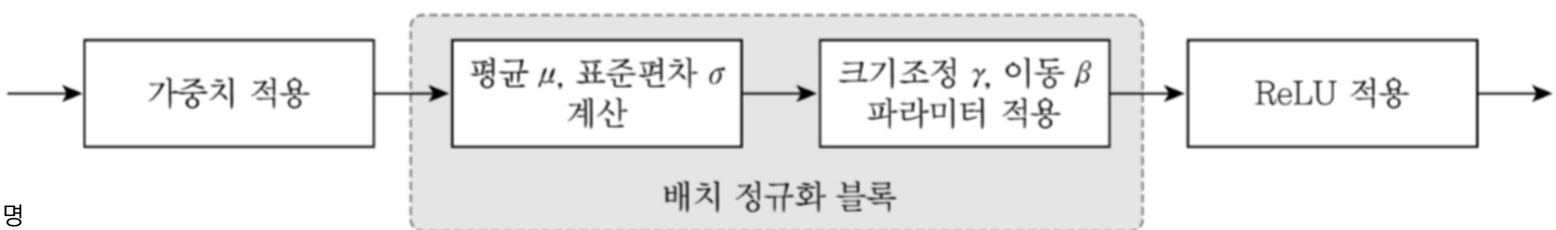

과적합 문제

❖ 배치 정규화 기법 – cont.

- **미니배치** B에 대해
  1. $\boldsymbol{x}_i$의 평균 $\boldsymbol{\mu}_B$가 0이 되고 표준편차 $\boldsymbol{\sigma}_B$는 I가 되도록 변환
  2. 크기조정(scaling) 파라미터 γ와 이동(shift) 파라미터 β 적용
  3. 변환된 데이터 $\boldsymbol{y}_i$ 생성

- 가중치 연산 결과의 미니 배치 : $B = \{\boldsymbol{x}_1, \boldsymbol{x}_2, \dots, \boldsymbol{x}_m\}$
- 배치 정규화 적용 결과 : $\{\boldsymbol{y}_1, \boldsymbol{y}_2, \dots, \boldsymbol{y}_m\}$

미니배치의 평균 : $\boldsymbol{\mu}_B = \frac{1}{m}\sum_{i=1}^{m}\boldsymbol{x}_i$

미니배치의 분산 : $\boldsymbol{\sigma}_B^2 = \frac{1}{m}\sum_{i=1}^{m}(\boldsymbol{x}_i - \boldsymbol{\mu}_B)^2$

정규화 : $\hat{\boldsymbol{x}}_i = \frac{\boldsymbol{x}_i - \boldsymbol{\mu}_B}{\sqrt{\boldsymbol{\sigma}_B^2 + \epsilon}}$

크기조정 및 이동변환 : $\boldsymbol{y}_i = \gamma\hat{\boldsymbol{x}}_i + \beta$

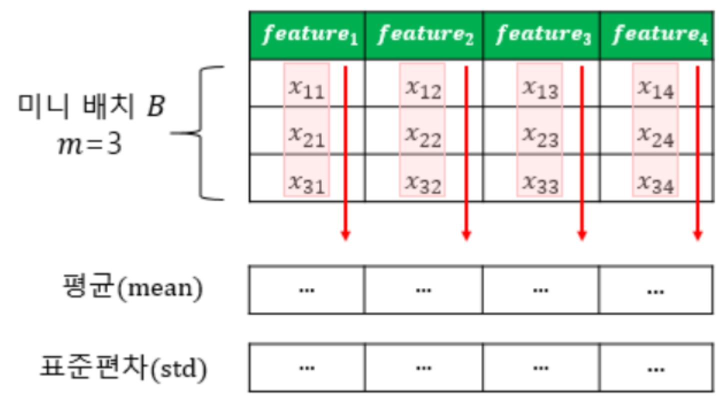

γ, β : 학습 대상 파라미터

과적합 문제

❖ **배치 정규화 기법 – cont.**

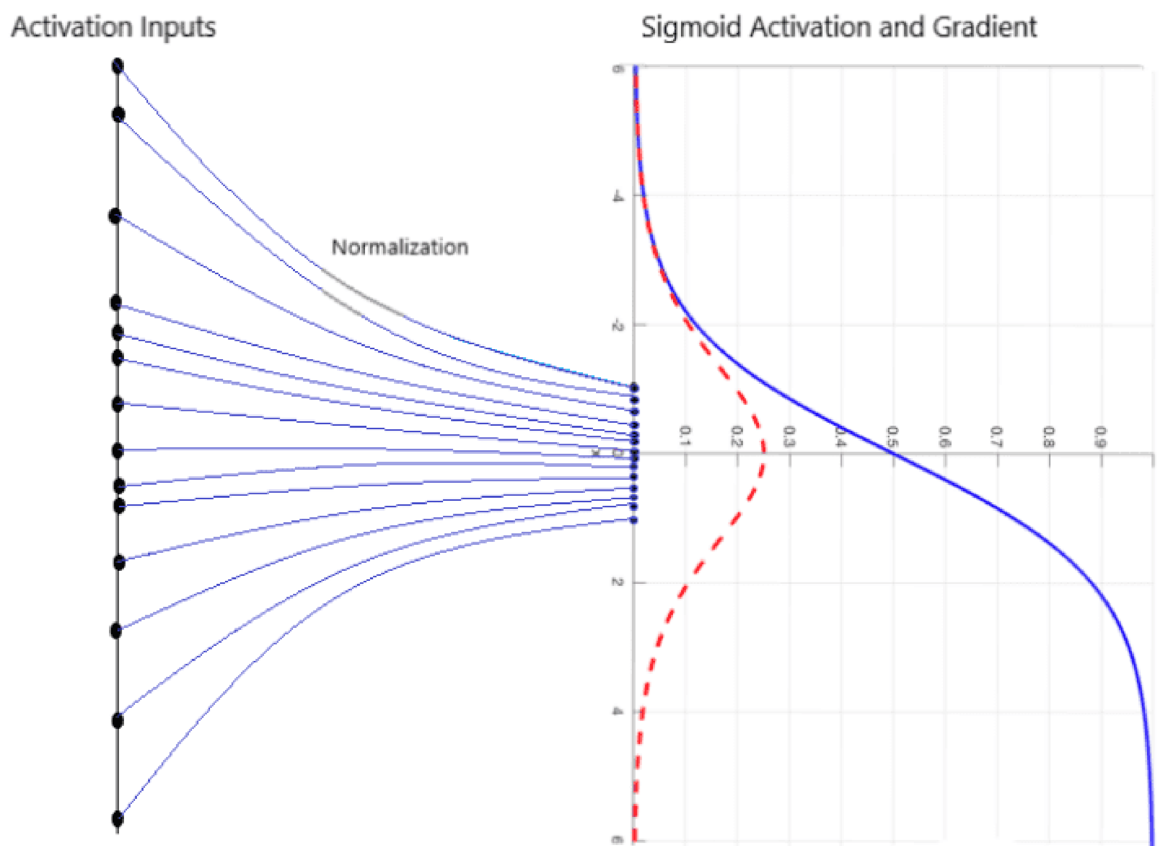

https://theaisummer.com/normalization/

5. 가중치 학습 기법(optimizer)

❖ 경사 하강법(Gradient descent method)

$$w^{(t+1)} = w^{(t)} - \eta \frac{\partial E(w^{(t)})}{\partial w}$$

❖ 모멘텀 사용 경사 하강법(Gradient descent method with Momentum)

$$\Delta^{(t)} = \alpha \Delta^{(t-1)} + \eta \frac{\partial E(w^{(t)})}{\partial w}$$

$$w^{(t+1)} = w^{(t)} - \Delta^{(t)}$$

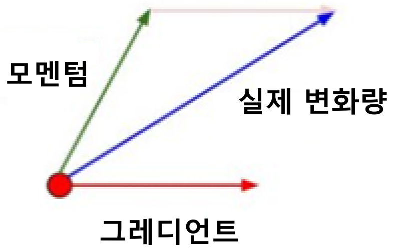

❖ NAG(Nesterov accelerated gradient)

$$\Delta^{(t)} = \alpha \Delta^{(t-1)} + \eta \frac{\partial E(w^{(t)} - \alpha \Delta^{(t-1)})}{\partial w}$$

$$w^{(t+1)} = w^{(t)} - \Delta^{(t)}$$

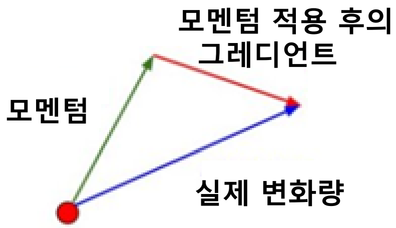

가중치 학습 기법

- **Adagrad (Adaptive Gradient Algorithm)**
  - 가중치 별도 다른 학습율 사용

$$g_i^{(t)} = \frac{\partial E(\boldsymbol{w}^{(t)})}{\partial w_i} \qquad G_i^{(t)} = G_i^{(t-1)} + \left(g_i^{(t)}\right)^2$$

$$w_i^{(t+1)} = w_i^{(t)} - \frac{\eta}{\sqrt{G_i^{(t)} + \epsilon}} g_i^{(t)}$$

- **Adadelta**
  - Adagrad의 확장
  - 과거 그레디언트의 영향을 점점 줄이면서 그레디언트 제곱합 계산

$$E[g_i^2]_t = \gamma E[g_i^2]_{t-1} + (1-\gamma)\left(g_i^{(t)}\right)^2 \qquad RMS[g_i]^{(t)} = \sqrt{E[g_i^2] + \epsilon}$$

$$E[w_i^2]_t = \gamma E[w_i^2]_{t-1} + (1-\gamma)\left(\frac{\eta}{RMS[g_i]^{(t)}} g_i^{(t)}\right)^2 \quad RMS[w_i]^{(t)} = \sqrt{E[w_i^2] + \epsilon}$$

$$w_i^{(t+1)} = w_i^{(t)} - \frac{RMS[w_i]^{(t-1)}}{RMS[g_i]^{(t)}} g_i^{(t)}$$

가중치 학습 기법

❖ RMSprop

- 가중치별 다른 학습율 사용
- 결합된 그레디언트 제곱의 합의 제곱근을 학습율로 사용

$$E[g_i^2]_t = \gamma E[g_i^2]_{t-1} + (1-\gamma)\left(g_i^{(t)}\right)^2$$

$$w_i^{(t+1)} = w_i^{(t)} - \frac{\eta}{\sqrt{E[g_i^2]^{(t)} + \epsilon}} g_i^{(t)}$$

❖ ADAM (Adaptive Moment Estimation)

- 가중치별 다른 학습율 사용
- 그레디언트의 1차, 2차 모멘텀 사용

$$m^{(t)} = \beta_1 m^{(t-1)} + (1-\beta_1) g_i^{(t)}$$

$$v^{(t)} = \beta_2 v^{(t-1)} + (1-\beta_2)\left(g_i^{(t)}\right)^2$$

$$w_i^{(t+1)} = w_i^{(t)} - \frac{\eta}{\sqrt{\hat{v}^{(t)} + \epsilon}} \hat{m}^{(t)}$$

$$\hat{m}^{(t)} = \frac{m^{(t)}}{1-\beta_1^{(t)}}$$

$$\hat{v}^{(t)} = \frac{v^{(t)}}{1-\beta_2^{(t)}}$$

가중치 학습 기법

❖ AdamW

- L2 정규화와 가중치 감소(weight decay) 방법을 함께 적용한 Adam

Algorithm 2 Adam with L_2 regularization and Adam with decoupled weight decay (AdamW)

given $\alpha = 0.001, \beta_1 = 0.9, \beta_2 = 0.999, \epsilon = 10^{-8}, \lambda \in \mathbb{R}$
initialize time step $t \leftarrow 0$, parameter vector $\boldsymbol{\theta}_{t=0} \in \mathbb{R}^n$, first moment vector $\boldsymbol{m}_{t=0} \leftarrow \boldsymbol{0}$, second moment vector $\boldsymbol{v}_{t=0} \leftarrow \boldsymbol{0}$, schedule multiplier $\eta_{t=0} \in \mathbb{R}$
repeat
  $t \leftarrow t + 1$
  $\nabla f_t(\boldsymbol{\theta}_{t-1}) \leftarrow \text{SelectBatch}(\boldsymbol{\theta}_{t-1})$ ▷ select batch and return the corresponding gradient
  $\boldsymbol{g}_t \leftarrow \nabla f_t(\boldsymbol{\theta}_{t-1}) \; +\lambda\boldsymbol{\theta}_{t-1}$
  $\boldsymbol{m}_t \leftarrow \beta_1 \boldsymbol{m}_{t-1} + (1-\beta_1)\boldsymbol{g}_t$ ▷ here and below all operations are element-wise
  $\boldsymbol{v}_t \leftarrow \beta_2 \boldsymbol{v}_{t-1} + (1-\beta_2)\boldsymbol{g}_t^2$
  $\hat{\boldsymbol{m}}_t \leftarrow \boldsymbol{m}_t/(1-\beta_1^t)$ ▷ β_1 is taken to the power of t
  $\hat{\boldsymbol{v}}_t \leftarrow \boldsymbol{v}_t/(1-\beta_2^t)$ ▷ β_2 is taken to the power of t
  $\eta_t \leftarrow \text{SetScheduleMultiplier}(t)$ ▷ can be fixed, decay, or also be used for warm restarts
  $\boldsymbol{\theta}_t \leftarrow \boldsymbol{\theta}_{t-1} - \eta_t \left(\alpha \hat{\boldsymbol{m}}_t / (\sqrt{\hat{\boldsymbol{v}}_t} + \epsilon) \; +\lambda\boldsymbol{\theta}_{t-1} \right)$
until *stopping criterion is met*
return optimized parameters $\boldsymbol{\theta}_t$

가중치 학습 기법

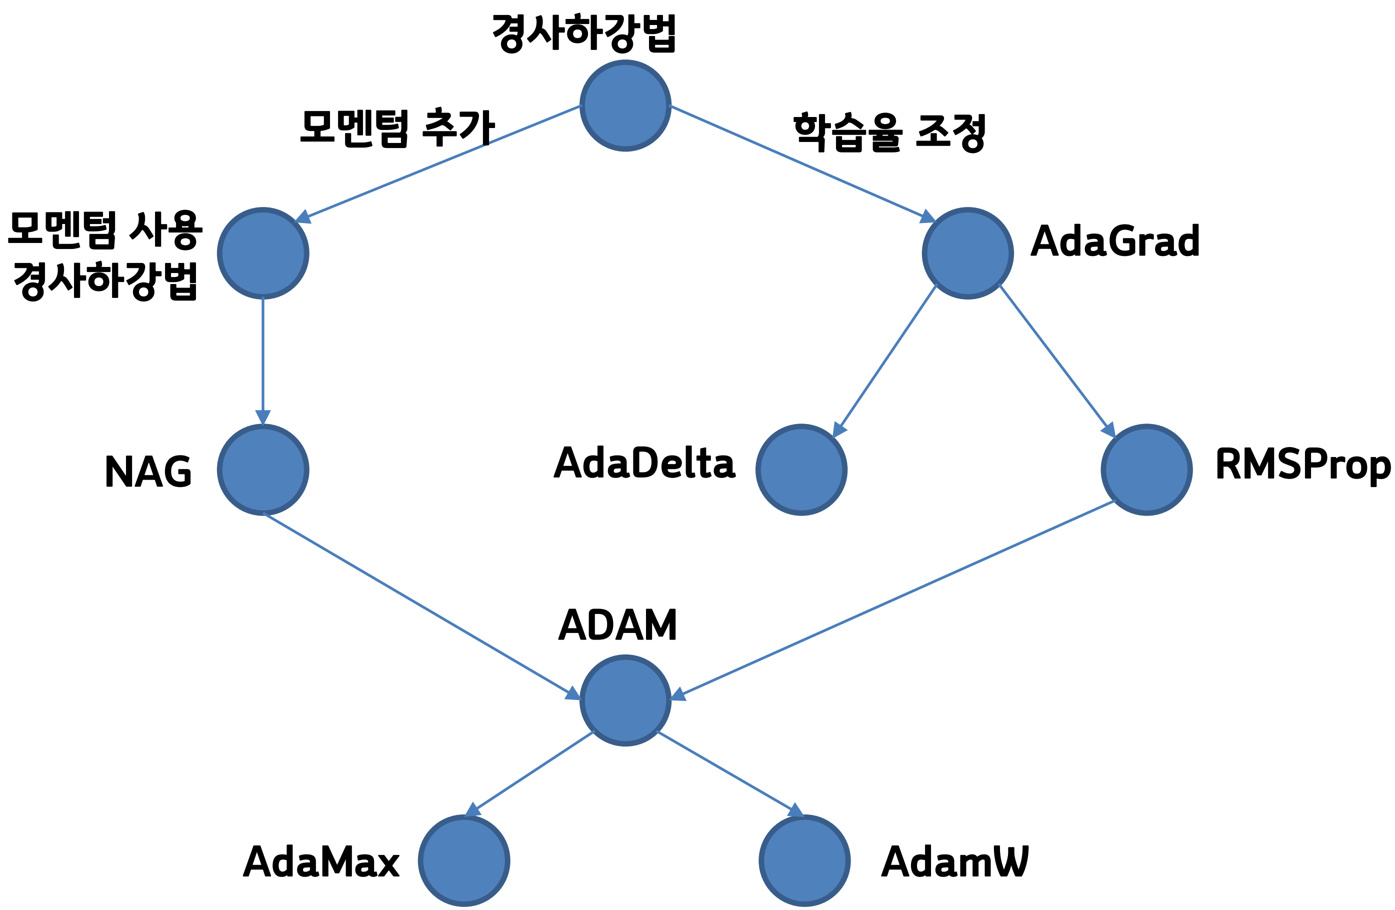
경사하강법
모멘텀 추가
학습율 조정
모멘텀 사용
경사하강법
AdaGrad
NAG
AdaDelta
RMSProp
ADAM
AdaMax
AdamW

가중치 학습 기법

❖ 여러 경사 하강법의 동작 형태

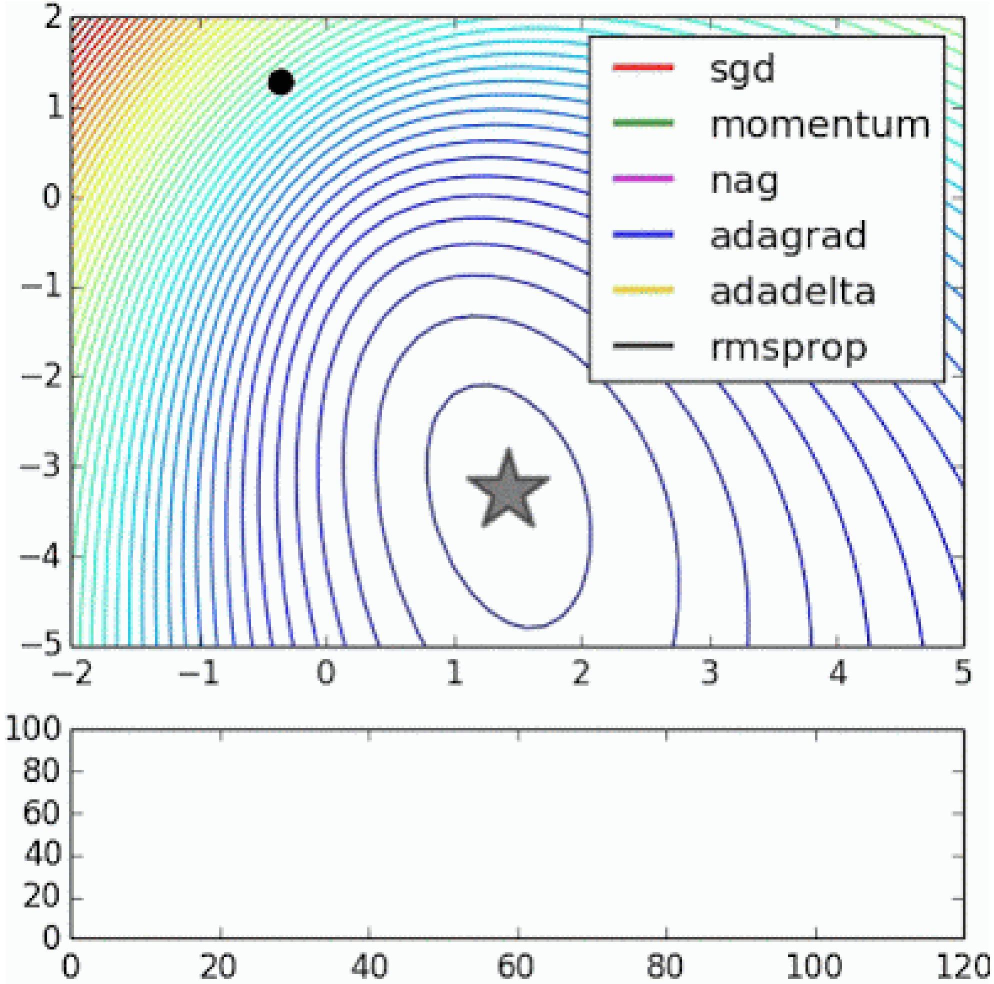

http://www.denizyuret.com/2015/03/alec-radfords-animations-for.html

가중치 학습 기법

❖ 여러 경사 하강법의 동작 형태

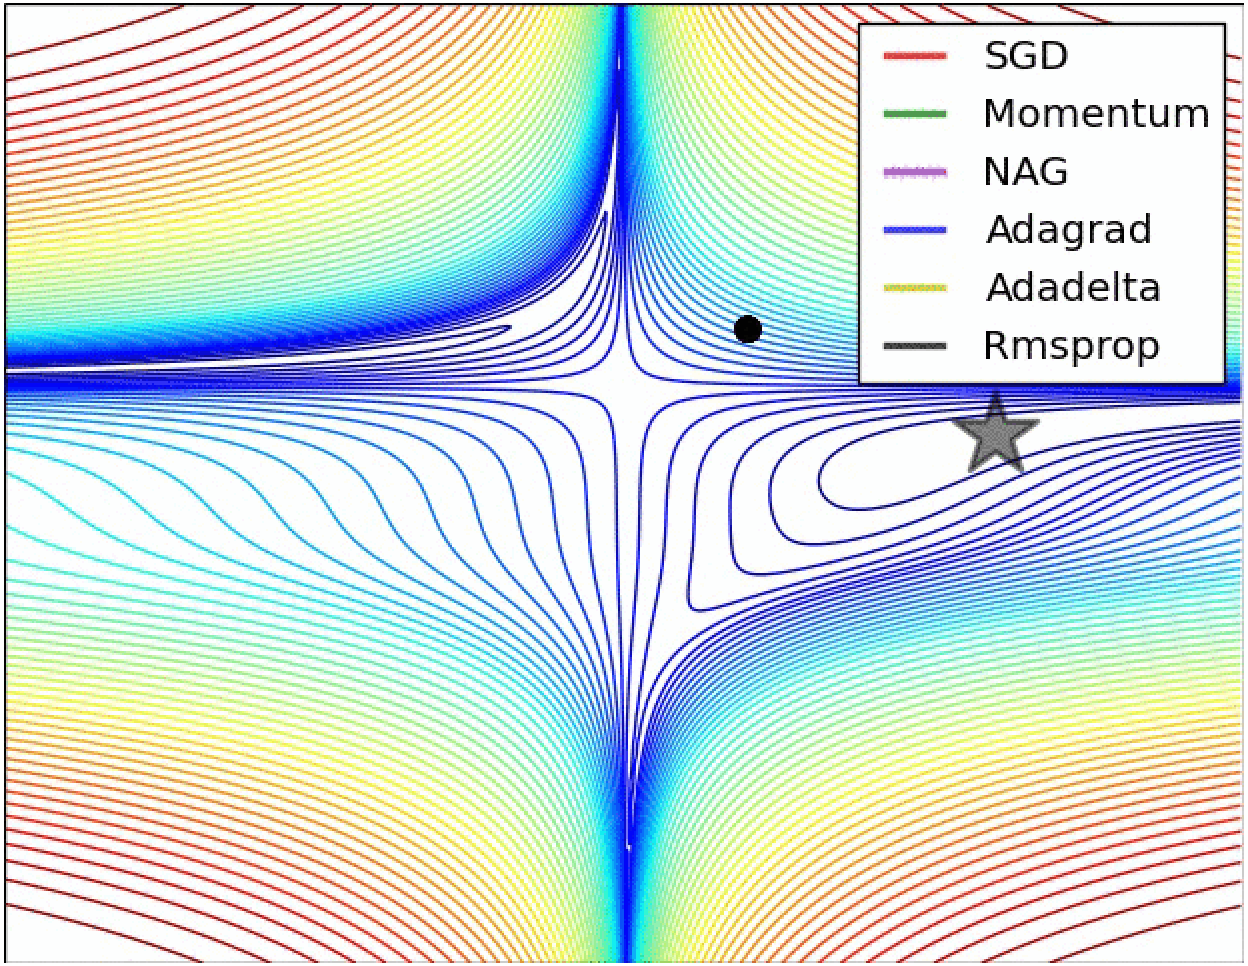

http://www.denizyuret.com/2015/03/alec-radfords-animations-for.html

가중치 학습 기법

❖ **여러 경사 하강법의 동작 형태**

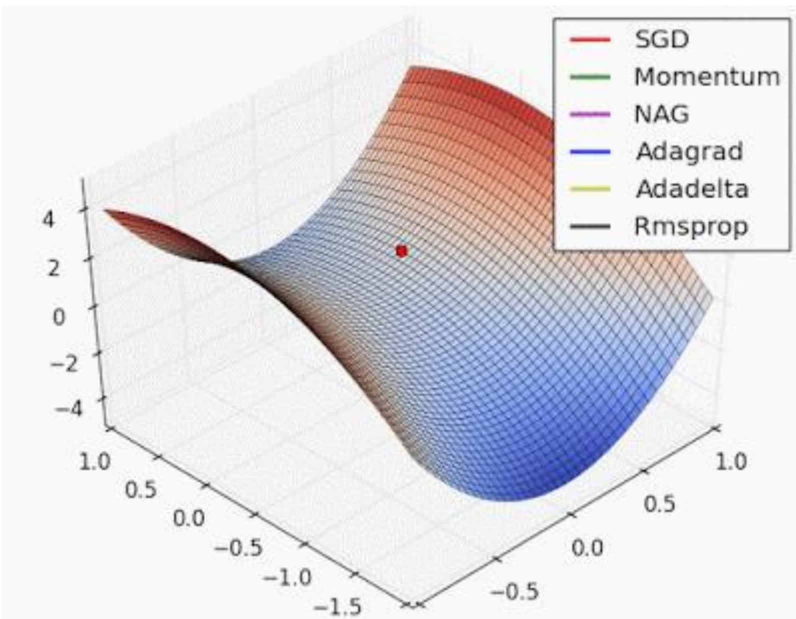

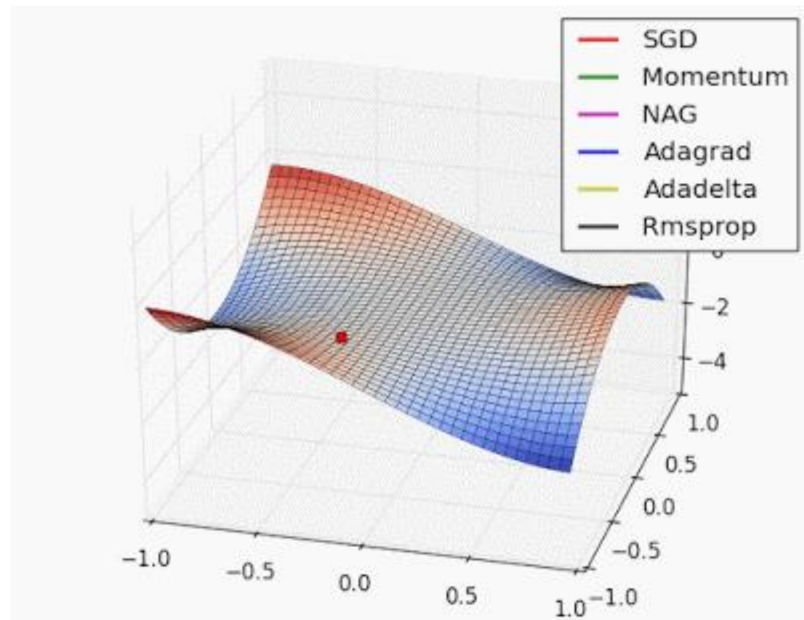

http://www.denizyuret.com/2015/03/alec-radfords-animations-for.html

[프로그래밍 실습: Gradient Descent]

```python
import numpy as np
import matplotlib.pyplot as plt
from sklearn.datasets import make_moons
from sklearn.model_selection import train_test_split

n_samples = 5000                    # 데이터 개수
minibatch_size = 50                 # 미니배치 크기

n_feature = 2
n_class = 2
X, y = make_moons(n_samples=5000, random_state=42, noise=0.1)
plt.scatter(X[:, 0], X[:, 1], marker='o', c=y, s=100,
            edgecolor="k", linewidth=2)
plt.xlabel("$X_1$")
plt.ylabel("$X_2$")
plt.show()

X_train, X_test, y_train, y_test = train_test_split(X, y, train_size=0.75, random_state=42)
```

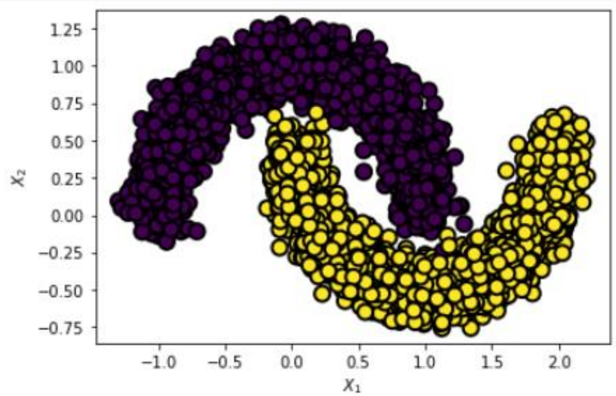

```python
def make_network(n_hidden=100):
    model = dict(
        W1 = np.random.randn(n_feature, n_hidden),
        W2 = np.random.randn(n_hidden, n_class)
    )
    return model

def softmax(x):
    return np.exp(x) / np.exp(x).sum()

def forward(x, model):
    h = x @ model['W1']                  # 입력과 가중치의 행렬곱
    h[h < 0] = 0                         # ReLU 연산 적용
    prob = softmax(h @ model['W2'])      # 출력층 계산
    return h, prob

def backward(model, xs, hs, errs):
    # xs, hs, errs : 미니배치의 전체 (input, hidden state, error)
    dW2 = hs.T @ errs
    dh = errs @ model['W2'].T
    dh[hs <= 0] = 0
    dW1 = xs.T @ dh
    return dict(W1=dW1, W2=dW2)
```

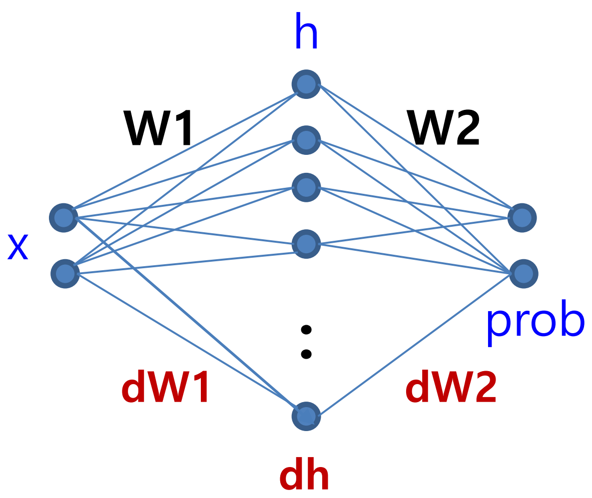

```python
n_iteration = int(len(X_train)/minibatch_size)    # iteration 수

def get_minibatch_grad(model, X_train, y_train):
    xs, hs, errs = [], [], []

    for x, cls_idx in zip(X_train, y_train):
        h, y_pred = forward(x, model)

        y_true = np.zeros(n_class)
        y_true[int(cls_idx)] = 1.

        err = y_true - y_pred   # 오차
        xs.append(x)      # 입력 저장
        hs.append(h)      # 은닉층 출력 저장
        errs.append(err)  # 오차 저장

    # 현재 미니배치를 이용한 Backprop
    return backward(model, np.array(xs), np.array(hs), np.array(errs))
```

Gradient Descent

```
def shuffle(X, y):
    indices = np.arange(X.shape[0])
    np.random.shuffle(indices)
    X = X[indices]
    y = y[indices]
    return X, y

def get_minibatch(X, y, minibatch_size):
    minibatches = []
    X, y = shuffle(X, y)

    for i in range(0, X.shape[0], minibatch_size):
        X_mini = X[i:i + minibatch_size]
        y_mini = y[i:i + minibatch_size]
        minibatches.append((X_mini, y_mini))

    return minibatches

def GradientDescent(model, X_train, y_train, minibatch_size, eta=1e-4):
    minibatches = get_minibatch(X_train, y_train, minibatch_size)
    for idx in range(0, n_iteration):
        X_mini, y_mini = minibatches[idx]
        grad = get_minibatch_grad(model, X_mini, y_mini)

        for layer in grad:
            model[layer] += eta * grad[layer]
    return model
```

$$\boldsymbol{w}^{(t+1)} = \boldsymbol{w}^{(t)} - \eta \frac{\partial E(\boldsymbol{w}^{(t)})}{\partial \boldsymbol{w}}$$

```
n_experiment = 100              # 실험회수
learning_rate = 1e-4            # 학습율
accs = np.zeros(n_experiment)   # 정확도 저장

for k in range(n_experiment):
    model = make_network()       # 신경망 구성
    model = GradientDescent(model, X_train, y_train, minibatch_size, learning_rate)
    y_pred = np.zeros_like(y_test)

    for i, x in enumerate(X_test):
        _, prob = forward(x, model)
        y = np.argmax(prob)
        y_pred[i] = y

    accs[k] = (y_pred == y_test).sum() / y_test.size    # 정확도 계산

print('정확도 평균: {}, 표준편차: {}'.format(accs.mean(), accs.std()))
```

```
정확도 평균: 0.8193520000000001, 표준편차: 0.07025199851961508
```

Quiz

❖ **일반 신경망과 딥러닝 신경망에 대한 설명으로 옳지 않은 것은?**

① 일반 신경망인 다층 퍼셉트론에서 은닉층의 개수는 2~3개 정도로 적다.
② 일반 신경망에서 특징 추출을 별로도 할 경우 개발자가 이를 처리해줘야 한다.
③ 딥러닝 신경망에서는 데이터에 대한 특징 추출 방법이 학습을 통해서 결정될 수 있다.
④ 기울기 소멸 문제는 계단 모양 활성 함수를 사용하여 완화시킬 수 있다.

❖ **다음 신경망의 학습에 대한 설명으로 옳지 않은 것은?**

① 시그모이드 함수의 미분값은 0.25이하인 양의 값이기 때문에, 이를 활성 함수로 사용하면 기울기 소멸 문제가 발생할 수 있다.
② ReLU 함수의 출력값은 0이 될 수 없다.
③ 제이비어(Xavier) 기법을 사용할 때 가중치의 초기값은 층(layer)에 있는 노드 개수에 영향을 받는다.
④ 동일한 학습 알고리즘을 적용하더라도 신경망에 있는 가중치의 초기값은 성능에 영향을 크게 줄 수 있다.

Quiz

❖ **과적합에 대한 설명으로 옳지 않은 것은?**

① 과적합 상태이면 테스트 데이터에 대한 성능이 학습 데이터에 대한 성능보다 좋다.

② 오차함수를 오차항과 모델 복잡도항으로 구성함으로써 과적합을 완화시킬 수 있다.

③ 학습할 때 일정 확률로 노드들을 무작위로 선택하여 해당 노드에 대한 연결선이 없는 것처럼 학습에 배제하는 드롭아웃은 과적합 해소에 도움이 된다.

④ 미니배치 단위로 가중치를 갱신하는 학습을 하면 과적합을 완화시키는데 도움이 될 수 있다.

❖ **다음 가중치 학습 기법에 대한 설명으로 옳지 않은 것은?**

① 딥러닝 신경망의 학습 알고리즘은 기본적으로 경사 하강법에 기반한다.

② 모멘텀 사용 경사 하강법에서는 직전 시점의 가중치 갱신 정보를 일부 활용하여 가중치를 갱신한다.

③ Adadelta 알고리즘은 가중치별로 학습율에 다르게 적용될 수 있도록 한다.

④ 현재 알려진 가중치 학습 기법 중 ADAM이 가장 성능이 우수한 기법이다.

Quiz

❖ 딥러닝 모델의 성능을 향상시키기 위해 사용하는 기법은 아닌 것은?

① 데이터 확대
② 정규화
③ 배치 정규화
④ 특성 삭제

❖ 일반신경망과 딥러닝 신경망에 대한 설명으로 옳지 않은 것은?

① 딥러닝 신경망은 층의 수가 많을수록 과적합에 취약하다.
② 일반 신경망은 과적합에 상대적으로 덜 취약하다.
③ 딥러닝 신경망은 자동으로 특징을 추출한다.
④ 일반 신경망은 깊은 구조를 가진다.

❖ 일반 신경망과 딥러닝 신경망의 주요 차이점은?

① 사용되는 뉴런의 수
② 네트워크의 깊이
③ 활성화 함수의 종류
④ 그래디언트 소멸 문제의 발생

Quiz

❖ 기울기 소멸 문제는 주로 어떤 모델에서 발생하는가?

① 얕은 신경망
② 깊은 신경망
③ 단일 계층 신경망
④ SVM

❖ 어떤 모델이 주로 복잡한 계층적 특징을 학습하는 데 적합한가?

① 얕은 신경망
② 깊은 신경망
③ 단일 계층 신경망
④ 선형 회귀 모델

❖ 딥러닝 신경망에서는 주로 어떤 유형의 활성화 함수를 사용하여 그래디언트 소멸 문제를 완화하는가?

① Sigmoid 함수
② Step 함수
③ ReLU
④ 선형 함수

Quiz

❖ 기울기 소멸 문제가 발생할 때, 가중치 업데이트는 어떤 특성을 보이는가?

① 지나치게 큰 업데이트
② 매우 작은 업데이트
③ 무작위한 업데이트
④ 일정한 크기의 업데이트

❖ 기울기 소멸 문제는 어떤 활성화 함수와 함께 발생할 가능성이 높은가?

① ReLU
② Leaky ReLU
③ Sigmoid
④ Softmax

❖ 어떤 활성화 함수가 입력 값의 모든 부분에서 미분 가능한가?

① ReLU
② Leaky ReLU
③ Sigmoid
④ Step function

Quiz

❖ **기울기 소멸 문제가 주로 발생하는 경우는?**

① 층이 많은 신경망에서

② 학습률이 너무 높을 때

③ 가중치가 무작위로 초기화될 때

④ 활성화 함수로 ReLU를 사용할 때

❖ **기울기 소멸 문제를 일으키는 활성화 함수는?**

① ReLU

② 시그모이드

③ Leaky ReLU

④ ELU

❖ **기울기 소멸 문제를 완화하는 방법 중 가장 잘못된 것은?**

① 적절한 가중치 초기화 방법 사용

② 활성화 함수로 ReLU 계열 함수 사용

③ 학습률을 점차 증가시키는 방법

④ 배치 정규화(Batch Normalization)

Quiz

❖ **신경망에서 초기 가중치 설정의 중요성에 대한 잘못된 설명은?**

① 초기 가중치는 학습의 시작점을 결정한다.
② 너무 큰 초기 가중치는 학습 과정을 불안정하게 만들 수 있다.
③ 모든 가중치를 같은 값으로 초기화하는 것이 바람직하다.
④ 초기 가중치는 무작위로 설정되거나 특정 기법을 사용하여 초기화된다.

❖ **신경망에서 배치 크기(Batch Size)의 역할에 대한 잘못된 설명은?**

① 한 번에 처리하는 데이터의 수를 결정한다.
② 너무 크면 학습 속도가 느려질 수 있다.
③ 아주 작게 하면 모델의 일반화 성능이 향상된다.
④ 메모리 용량과 계산 속도에 영향을 준다.

❖ **신경망에서 손실 함수(Loss Function)의 목적에 대한 잘못된 설명은?**

① 예측값과 실제값 간의 차이를 측정한다.
② 학습 과정에서 최소화되어야 한다.
③ 손실 함수의 선택은 문제 유형에 따라 달라진다.
④ 손실 함수의 값은 학습 과정에 영향을 주지 않는다.

Quiz

❖ **가중치 초기화에서 0으로 초기화하는 방법의 문제점은?**

① 신경망이 대칭적인 가중치를 갖게 되어 학습이 제대로 이루어지지 않는다.
② 0으로 초기화하면 뉴런의 출력이 항상 0이 되어 학습이 이루어질 수 없다.
③ 가중치 감소(weight decay) 기법을 적용할 때 문제가 발생할 수 있다.
④ 모든 가중치가 같은 값을 갖기 때문에 기울기 소멸 문제가 발생한다.

❖ **Xavier 초기화 방법의 주된 특징은?**

① 가중치를 일정 범위 내에서 균등하게 분포시키는 방법이다.
② 초기 가중치를 큰 값으로 설정하여 활성화 함수의 비선형 영역을 활용한다.
③ 각 층의 입력 노드의 개수에 따라 분산의 크기를 조정한다.
④ 무작위성을 최대화하여 모든 가중치가 다른 값을 갖도록 한다.

❖ **He 초기화 방법에서 사용하는 분산의 계산에 사용되는 요소는?**

① 은닉층의 노드 수
② 학습률
③ 각 층의 입력 노드 수
④ 가중치의 개수

Quiz

❖ **L1 규제화는 어떤 특징을 가지고 있는가?**

① 가중치의 제곱을 규제
② 가중치의 절댓값을 규제
③ 가중치의 합을 규제
④ 가중치의 제곱근을 규제

❖ **규제화는 어떤 상황에서 효과적인가요?**

① 훈련 데이터가 충분할 때
② 모델이 너무 단순할 때
③ 모델이 너무 복잡할 때
④ 훈련 데이터가 아주 적을 때

❖ **규제화를 사용할 때 주의해야 할 점은?**

① 너무 강한 규제는 과소적합을 일으킬 수 있음
② 규제는 항상 모델의 성능을 향상시킴
③ 규제는 항상 모델의 학습 속도를 늦춤
④ 규제는 모든 문제에 적합하다

Quiz

❖ **배치 정규화(Batch Normalization)의 주된 목적은?**

① 과적합 방지
② 학습 속도 개선
③ 모델의 계산 복잡도 감소
④ 모델의 크기 축소

❖ **배치 정규화는 어느 위치에 주로 적용되는가?**

① 활성화 함수 전
② 활성화 함수 후
③ 손실 함수 전
④ 최적화 함수 후

❖ **배치 정규화에서 계산할 필요가 있는 것은?**

① 평균과 분산
② 가중치와 편향
③ 학습률과 모멘텀
④ 손실 값과 그래디언트 값

Quiz

❖ **배치 정규화는 어떤 값을 이용해 정규화하는가?**

① 한 배치 내의 데이터들의 중앙값
② 전체 데이터의 평균값
③ 한 배치 내의 데이터들의 평균값
④ 전체 데이터의 중앙값

❖ **배치 정규화에서 발생하는 연산이 아닌 것은?**

① 스케일(scale) 조정
② 이동(shift)
③ 회전(rotation)
④ 정규화(normalization)

❖ **배치 정규화의 장점은?**

① 더 큰 학습률을 사용할 수 있게 해줌
② 가중치 초기화의 영향을 줄여줌
③ 내부 공변량 변화를 완화
④ 모델의 크기를 물리적으로 줄여줌

Quiz

❖ **경사하강법(Gradient Descent)의 핵심 아이디어는?**

① 손실 함수의 최대값을 찾는 것
② 모든 가중치를 무작위로 조정하는 것
③ 손실 함수의 그래디언트를 사용하여 가중치를 업데이트하는 것
④ 모든 샘플에 대해 개별적으로 가중치를 업데이트하는 것

❖ **Momentum 방법을 사용할 때, 어떤 변수가 이전 그래디언트 값을 사용하는가?**

① 학습률
② 가중치
③ 손실 함수
④ 속도(velocity)

❖ **AdaGrad의 특징은?**

① 과거의 모든 그래디언트의 제곱을 누적한다.
② 속도와 방향을 모두 고려한다.
③ 학습률을 일정하게 유지한다.
④ 모멘텀만을 사용하여 가중치를 업데이트한다.

Quiz

❖ **RMSProp의 핵심 아이디어는?**

① 과거 그레디언트의 제곱의 이동 평균을 유지한다.
② 모든 가중치 업데이트는 동일한 크기로 수행된다.
③ 학습률이 시간에 따라 증가한다.
④ 경사하강법과 동일한 방식으로 작동한다.

❖ **Adam는 어떤 최적화 기법의 조합으로 볼 수 있는가?**

① RMSProp + AdaGrad
② RMSProp + Momentum
③ Gradient Descent + Momentum
④ AdaGrad + Gradient Descent

❖ **미니배치 경사하강법은 어떤 방식으로 데이터를 처리하는가?**

① 한 번에 하나의 샘플만 처리한다.
② 전체 데이터 세트를 한 번에 처리한다.
③ 데이터 세트의 작은 부분집합을 한 번에 처리한다.
④ 데이터의 순서를 고려하지 않고 무작위로 처리한다.

Quiz

- **어떤 최적화기가 학습률을 동적으로 조정하는 기능을 가지고 있는가?**
  ① Gradient Descent
  ② Momentum
  ③ AdaGrad
  ④ Batch Gradient Descent

- **최적화기(optimizer)의 학습률을 너무 높게 설정하면 어떤 문제가 발생할 수 있는가?**
  ① 모델이 과소적합될 수 있다.
  ② 손실 함수의 최소값에 수렴하기 위해 더 많은 시간이 걸릴 수 있다.
  ③ 손실 함수의 최소값 주변에서 진동할 수 있다.
  ④ 학습이 전혀 진행되지 않는다.

- **saddle point(안장점)에 빠질 경우, 어떤 최적화기가 이를 해결하는 데 가장 도움이 안될까?**
  ① Gradient Descent
  ② Momentum
  ③ Batch Gradient Descent
  ④ AdaGrad

Quiz

❖ 학습 데이터의 특징 Z가 평균 0, 표준 편차 1로 정규화되어야 할 때, 원본 데이터 값 $[2,8,-1,4]$를 정규화하고 변환된 값을 계산하세요.

❖ 학습률이 0.01이고, 현재 가중치가 0.5일 때, 손실 함수의 그래디언트가 0.3으로 계산되었을 때, 다음 단계의 가중치를 계산하시오.

❖ 데이터 배치가 [1, 3, 5, 7]로 주어졌을 때, 이 데이터의 평균과 표준편차를 계산하시오.

❖ 위에서 계산한 평균과 표준편차를 사용하여 각 데이터 포인트를 정규화하시오.

❖ 위에서 정규화된 데이터에 학습 가능한 매개변수 $\gamma = 2$와 $\beta = 0.5$를 적용하여 출력을 계산하시오.