



The Apprentice Project

Lec05: Linear Regression (Part 2)

충북대학교

문성태 (지능로봇공학과)

stmoon@cbnu.ac.kr

04

Linear Regression with MLE

(Part I: Probability)

Probability – Random variable

- 확률 변수 (random variable)


- Ex) 윷




- 다섯 가지 경우 중 한 값을 갖는 확률변수 x
 - x 의 정의역은 {도, 개, 걸, 윷, 모}

Probability – Random variable

- 확률 분포




(a) 이산인 경우의 확률질량함수



(b) 연속인 경우의 확률밀도함수

Probability – Example

- 주머니에서 번호를 뽑은 다음, 번호에 따라 해당 병에서 공을 뽑고 색을 관찰함
- 번호를 y , 공의 색을 x 라는 확률변수로 표현하면 정의역은 $y \in \{①, ②, ③\}$,
 $x \in \{\text{파랑, 하양}\}$



Probability – 곱의 규칙

- 곱의 규칙
 - 두 사건 A, B에 대하여 사건 A가 일어나는 경우의 수가 m이고, 그 각각에 대하여 사건 B가 일어나는 경우의 수가 n이면 두 사건 A, B가 연이어 일어나는 경우의 수는 $m \cdot n$ 이다
 - ①번 카드를 뽑을 확률은 $P(y=\textcircled{1})=P(\textcircled{1})=1/8$
 - 카드는 ①번, 공은 하얀색일 확률은 $P(y=\textcircled{1}, x=\text{하얀색}) = P(\textcircled{1}, \text{하얀색}) \leftarrow$ 결합확률

$$\text{곱 규칙: } P(y, x) = P(x|y)P(y)$$

Probability – 합의 규칙

- 합의 규칙
 - 두 사건 A, B가 동시에 일어나지 않을 때, 사건 A와 사건 B가 일어나는 경우의 수가 각각 m, n이면 사건 A 또는 사건 B가 일어나는 경우의 수는 $m+n$ 이다


$$\text{합 규칙: } P(x) = \sum_y P(y, x) = \sum_y P(x|y)P(y)$$

Bayes' theorem

$$P(y, x) = P(x|y)P(y) = P(x, y) = P(y|x)P(x)$$


$$P(y|x) = \frac{P(x|y) P(y)}{P(x)}$$

Example - Bayes' theorem #1



“하얀 공이 나왔다는 사실만 알고 어느 병에서 나왔는지 모르는데, 어느 병인지 추정하라.”

Example - Bayes' theorem #2



Bayes' theorem

X : 관측치 (Data) : D

θ : 모수 (Population Parameter) : H

$$P(\theta \mid X) = \frac{P(X|\theta)P(\theta)}{P(X)}$$

Likelihood

- Probability
 - 주어진 확률분포가 있을 때, 관측값 혹은 관측 구간이 분포 안에서 얼마의 확률로 존재하는 지를 나타내는 값
- Likelihood
 - 어떤 값이 관측되었을 때, 해당 관측값이 어떤 확률분포로부터 나왔는지에 대한 확률
 - "확률"의 개념과는 반대로 고정되는 요소가 확률분포가 아닌 관측값 D

Maximum Likelihood Estimation (MLE)

- 각 관측값 x 에 대한 총 가능도(즉, 모든 가능도의 곱)가 최대가 되게 하는 확률분포를 찾는 것

Maximum Likelihood Estimation (MLE)

- 모든 관측 데이터가 독립적이라고 가정
- 곱셈의 경우 데이터의 개수가 많아질 수록 값이 작아지고, 미분이 어려워 \log 를 취한 \log likelihood 활용
- 미분을 통해 최소값을 구하기 위해 "-" 활용

05

Linear Regression with MLE

(Part II: MLE)

Maximum Likelihood Estimation

- 잔차 항이 정규분포를 따른다고 가정 $\rightarrow \epsilon \sim N(0, \sigma^2)$

$$\hat{y}_i = w_1 x_{1,i} + w_2 x_{2,i} + \dots + w_k x_{k,i} + b$$

Maximum Likelihood Estimation

$$\max_{w, b} \log(L(w, b)) = \max_{w, b} \left(- \sum_i \left(y_i - \hat{y}_i \right)^2 \right)$$

06


Performance Evaluation for Linear Regression

Performance Evaluation

- 전체 데이터를 학습용과 평가용으로 나눈 다음, 학습용 데이터로 회기평면 추정
- 평가용 데이터에 적용하여 성능 평가
- 평가 방법
 - MSE (Mean Square Error)
 - R^2 (결정 계수)

$$MSE = \frac{1}{n} \sum_i^n (y_i - \hat{y}_i)^2$$

Coefficient of Determination (R^2 , 결정계수)




07



Regularization

Overfitting

- 학습데이터에 너무 최적화되어 W 값이 잡히고, 이후 학습 데이터가 아닌 새로운 데이터에는 올바른 값을 내보내지 못하는 현상



Overfitting vs Underfitting



Solution for Overfitting

- 학습 데이터 양을 늘리기
- Batch Normalization
- 모델의 복잡도 줄이기
- Drop-Out
- Regularization

Regularization





- 과대 적합을 완화하기 위한 대표적인 방법
- L1 Regularization (ex: Lasso)
- L2 Regularization (ex: Ridge)

Norm

- N-Norm
- L1/L2 Norm





Ridge Regression

- 계수의 제곱한 값을 기준으로 규제



Lasso Regression

- 계수의 절대값을 기준으로 규제



특정 feature를 선택하고자 하는 경향이 있음

Lasso vs Ridge


- Lasso (L1)

- _____
- _____
- _____

- Ridge (L2)

- _____
- _____
- _____

$$\sum_{j=1}^2 |w_i| \leq s$$



$$\sum_{j=1}^2 (w_i)^2 \leq s$$

